

1	Manipulació de conjunts de dades	2
1.1	Ordenar	2
1.2	Calcular una nova variable	2
1.3	Codificar	2
1.4	Fusionar taules	3
1.5	Seleccionar casos	3
1.6	Eliminar casos o variables	3
2	Estadística descriptiva d'una variable categòrica o qualitativa	4
2.1	Exemples de variables categòriques o qualitatives	4
2.2	Estadístics	5
2.3	Taules de freqüències	6
2.4	Gràfics	6
3	Exercicis	8

Part 1

Manipulació de conjunts de dades

A continuació veurem un resum de comandes classificades per la seva utilitat principal des del punt de vista de l'estadística. Val a dir que, per a cadascuna d'elles, hi ha altres funcions a R que fan el mateix. Aquí donarem un procediment o funció bàsica i us deixem a vosaltres explorar-ne més!

Cap al final us proposem la resolució d'una col·lecció d'exercicis, utilitzant aquestes eines i les funcions d'estadística descriptiva de R.

1.1 Ordenar

Podem ordenar un vector amb la comanda `sort` i obtenir les posicions d'ordenació amb la funció `order`

```
>sort(TE$pes)
>order(TE$pes)
```

Per ordenar un `data.frame` segons una variable, podríem fer:

```
>TE
>TE[c(2,1),]
>TE[order(TE$pes),]
```

Funciona? Per tal d'entendre com funciona, proveu-ho amb una taula més petita.

1.2 Calcular una nova variable

Una opció bàsica es `transform`. En la majoria dels casos també podem utilitzar `data.frame`. Per exemple, afegim una nova variable, IMC, que sigui l'índex de massa corporal:

```
>TE<-transform(TE, IMC=pes/altura^2) # o bé
>TE<-data.frame(TE, IMC=TE$pes/TE$altura^2)
```

1.3 Codificar

Anem a codificar la variable IMC en una nova variable, `IMCmod`, posant 1 si és menor que 22 i 0 si és major (potser caldrà que, abans, carregueu la llibreria `car`):

```
>TE<-data.frame(TE,IMCmod=recode(TE$IMC,"lo:22=1;else=0"))
```

1.4 Fusionar taules

Podem usar `data.frame` directament i ajuntar (concatenar) les dues taules, sense tenir en compte els individus. Així mateix podríem usar `cbind` o bé `rbind`. Una opció que té en compte els individus, quan enganxa les taules, és la funció `merge`. Observeu:

```
>taula1<-data.frame(nom=c("Pere","Joan","Maria"),nota1=c(5,6,9))
>taula2<-data.frame(nom=c("Maria","Pere","Eric","Joan"),nota2=c(3,7,8,6))
>merge(taula1,taula2,by="nom", all=T)
```

1.5 Seleccionar casos

Per a seleccionar casos, és a dir extreure'ls en una nova taula, l'opció més natural és `subset`. També podem fer-ho directament, usant l'estructura de matriu. Per exemple, si ens volem quedar només amb els que tenen IMC menor que 22, fem:

```
>subset(TE,IMCmod==1) # o bé
>TE[TE$IMCmod==1,]
```

1.6 Eliminar casos o variables

Si volem treure la segona fila de la taula, farem:

```
>TE<-TE[-2,]
```

Si volem treure la segona columna:

```
>TE<-TE[, -2]
```

Aquestes són instruccions heretades de la classe `matrix`. Podríem explorar-ne d'altres, més sofisticades i específiques dels `data.frame`.

Part 2

Estadística descriptiva d'una variable categòrica o qualitativa

Utilitzarem el procediment categòric o qualitatiu si tenim certesa que el nombre de valors diferents presents en les dades no és elevat, en altre cas, podríem col·lapsar l'R.

Recordeu que l'estadística descriptiva consisteix en la descripció de les dades mitjançant: estadístics, taules de freqüències i gràfics, així com comentaris que contribueixen a caracteritzar les dades.

2.1 Exemples de variables categòriques o qualitatives

Un exemple senzill, dades corresponents al sexe de certs individus:

```
>sexe<-c("h","d","d","h","h","h","d")
```

Useu el procediment categòric o qualitatiu ja que és evident que el nombre de valors possibles de la variable no és elevat, són 2: “h” i “d”. Alerta, ja que el fet que prengui valors alfanumèrics no seria motiu per tractar-la com a categòrica.

Un altre exemple: El nombre de fills de certs individus triats a l'atzar d'entre tots els treballadors de la UAB. La podem anomenar, `fills`:

```
>fills<-c(1,2,2,1,3,2,1,1,2,3,3)
```

Un exemple més: Un corrector automàtic de textos compta el nombre d'errors que troba en cada pàgina. Després de passar aquest corrector per un text de 50 pàgines, obtenim la variable `errors`:

```
>errors<-c( 2, 3, 5, 0, 1, 4, 0, 6, 2, 1, 1, 0, 2, 4, 5, 3, 1,
2, 3, 2, 2, 5, 4, 1, 3, 2, 6, 8, 2, 0, 1, 0, 2, 3, 1, 5, 10, 2, 1,
3, 3, 1, 2, 4, 4, 6, 2, 0, 1, 3)
```

Als dos darrers exemples, usem el procediment categòric o qualitatiu ja que és evident que el nombre de valors possibles de la variable no serà elevat, tot i que no sabem quants.

Un exemple més delicat: La nota de matemàtiques obtinguda pels alumnes de certa escola del Maresme. Cal fixar-se en com s'ha mesurat. Hi ha 36 suspesos, 21 aprovats, 22 notables i 21 excel·lents. Així l'anomenem `NotaCat`:

```
>NotaCat<-c(rep("S",36),rep("A",21),rep("N",22),rep("E",21))
```

També podríem introduir exactament el valor de la nota, ja que les notes obtingudes han estat:

```
>NotaNum<-c(10 , 10 , 10 , 10 , 10 , 9.9 , 9.9 , 9.9 , 9.9 , 9.8 ,
9.8 , 9.7 , 9.6 , 9.4 , 9.2 , 9.1 , 9.1 , 9 , 9 , 8.9 , 8.8 , 8.4 ,
8.4 , 8.3 , 8 , 7.9 , 7.8 , 7.7 , 7.7 , 7.5 , 7.5 , 7.5 , 7.5 , 7.5,
7.5 , 7.3 , 7.3 , 7.2 , 7.2 , 7 , 6.9 , 6.8 , 6.7 , 6.4 , 6.2 , 6.2 ,
6 , 5.9 , 5.9 , 5.7 , 5.6 , 5.6 , 5.6 , 5.6 , 5.6 , 5.5 , 5.4 , 5 ,
5 , 5 , 4.9 , 4.9 , 4.8 , 4.5 , 4.4 , 4.4 , 4.3 , 4.3 , 4.2 , 4.1 ,
4 , 4 , 3.9 , 3.5 , 3.4 , 3.1 , 3.1 , 3.1 , 3 , 3 , 2.7 , 2.7, 2.6 ,
2.5 , 2.3 , 2.2 , 2.2 , 2 , 2 , 1.9 , 1.8 , 1.7 , 1.2 , 1 , 0.3 ,
0.2 , 0.1 , 0.1 , 0.1 , 0.1)
```

Per a **NotaCat** usem el procediment categòric o qualitatiu ja que és evident que el nombre de valors possibles de la variable no és elevat. Ara bé, per a **NotaNum** caldrà usar el procediment numèric o quantitatiu, que veurem en una altra sessió. Finalment considerem les notes sense decimals i l'anomenem **Nota**:

```
>Nota<-c( 10 , 10 , 10 , 10 , 10 , 10 , 10 , 10 , 10 , 10 , 10 , 10 ,
10 , 9 , 9 , 9 , 9 , 9 , 9 , 9 , 9 , 8 , 8 , 8 , 8 , 8 , 8 , 8 ,
8 , 8 , 8 , 8 , 8 , 8 , 7 , 7 , 7 , 7 , 7 , 7 , 7 , 6 , 6 , 6 ,
6 , 6 , 6 , 6 , 6 , 6 , 6 , 6 , 6 , 6 , 5 , 5 , 5 , 5 , 5 , 5 ,
5 , 4 , 4 , 4 , 4 , 4 , 4 , 4 , 4 , 4 , 4 , 3 , 3 , 3 , 3 , 3 ,
3 , 3 , 3 , 3 , 2 , 2 , 2 , 2 , 2 , 2 , 2 , 2 , 1 , 1 , 0 , 0 ,
0 , 0 , 0)
```

Com que només tenim 11 possibles valors, seria correcte usar alguns elements del procediment categòric o qualitatiu i d'altres del numèric o quantitatiu.

2.2 Estadístics

La comanda **summary** proporciona un resum dels estadístics bàsics en funció de la classe de la variable. Observeu:

```
>summary(sexe)
Length      Class      Mode
      7 character character
>summary(fills)
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
1.000  1.000  2.000  1.909  2.500  3.000
>summary(NotaCat)
Length      Class      Mode
     100 character character
>summary(Nota)
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
0.00   3.00   6.00   5.76   8.00  10.00
>summary(factor(Nota))
0  1  2  3  4  5  6  7  8  9 10
6  2  8 10 10  8 13  8 14  8 13
```

També tenim instruccions específiques per a demanar cadascun dels estadístics. Per a la mida, el mínim, el màxim, la mediana i els quantils tenim **length**, **min**, **max**, **median**, i **quantile**, respectivament. Per exemple, per a la variable **sexe**, donat que els seus valors no tenen un ordre (és nominal), els estadístics que considerarem són la llargada i la moda. Per a la variable **fills** té sentit considerar els quantils. Practiquem una mica amb la variable **errors**:

```

>length(errors)
>min(errors)
>max(errors)
>quantile(errors)
>quantile(errors, p=c(0.20, 0.80))

```

Us animem a treballar amb les altres variables.

2.3 Taules de freqüències

Les instruccions següents produeixen, respectivament, una taula de freqüències absolutes, freqüències absolutes acumulades, freqüències relatives i freqüències relatives acumulades de la variable **errors**. Fixeu-vos que utilitzem les funcions **table** i **cumsum**. Aquesta última produeix una “cumulative sum” dels elements d’un vector, essent el resultat un altre vector.

```

>table(errors)
>cumsum(table(errors))
>table(errors)/length(errors)
>cumsum(table(errors)/length(errors))

```

Podríem guardar-ho en format de taula fent:

```

>FreqAbs<-c(table(errors))
>FreqAbsAcum<-cumsum(table(errors))
>FreqRel<-c(table(errors)/length(errors))
>FreqRelAcum<-cumsum(table(errors)/length(errors))
>TaulaFreq<-data.frame(FreqAbs,FreqAbsAcum,FreqRel,FreqRelAcum)

```

2.4 Gràfics

Hi ha molts gràfics disponibles per a representar gràficament unes dades. Aquí us mostrem el més senzill: el *diagrama de barres*, que consisteix en representar gràficament la taula de freqüències absolutes (o relatives). La funció corresponent a R és **barplot**.

Podríem utilitzar les sortides anteriors, però aprofitem per a veure una altra manera d’obtenir la taula de freqüències absolutes. Ho fem amb la variable **fills**:

```

>TaulaFreqAbs<-summary(factor(fills))

```

Així, per a representar-los podem fer:

```

>barplot(TaulaFreqAbs)

```

És important que tinguem cura dels elements d’un gràfic: títol, nom d’eixos, colors, etc... Per exemple, modifiquem l’espai entre les barres:

```

>barplot(TaulaFreqAbs, space=1)

```

Useu la comanda **help** per explorar altres propietats del gràfic, fixeu-vos que el valor predeterminat de l’argument **space** és 0.2 i que amb 0 les barres estarien juntes. Observeu atentament què fa cadascun dels arguments del llistat següent i experimenteu amb ells:

```
>barplot(TaulaFreqAbs, space=1, names.arg=c("un","dos","tres"), angle=30,
  col=c("blue","red"), border="red", main="Nombre de fills",
  sub="Exemple de diagrama de barres", xlab="freqüència", ylab="fills",
  axes=FALSE, horiz=TRUE)
```

Observeu la re-utilització dels colors de l'argument `col`. Un altre gràfic interessant i senzill és el *diagrama de sectors*. La instrucció per a generar diagrames de sectors és `pie`. Per exemple, anem a fer el gràfic de sectors de la variable `sexe`:

```
>pie(summary(factor(sexe)))
```

Us animem a explorar altres propietats del diagrama de sectors.

Part 3

Exercicis

Exercici 3.1. En aquest exercici utilitzarem el `data.frame` “`classe`”, creat als exercicis del Mòdul 1 amb la comanda:

```
read.table('http://mat.uab.cat/~sintes/dades/DATA.txt', header = TRUE)
```

- Si cal, utilitzeu-la novament per a importar les dades del document de text “`DATA.txt`”, a un `data.frame` anomenat `classe`.
- Amplieu el `data.frame` `classe` amb la variable $IMC = \frac{pes}{altura^2}$ (secció 1.2) i les variables indicadores dels següents esdeveniments:

$$A = \{SEXE = D\} , B = \{SEXE = H\} \text{ i } C = \{PES > 150\} .$$

Aquestes variables han de tenir el valor 1 en els casos que compleixen la definició de l'esdeveniment, i el valor 0 en la resta dels casos. El `data.frame` ampliat anomeu-lo `classe2`.

Exercici 3.2. Feu un estudi descriptiu complet (amb taules de freqüències i representacions gràfiques) de cadascuna de les variables categòriques del `data.frame` `classe2`, de l'exercici anterior.

Exercici 3.3. En aquest exercici volem repetir els 2 exercicis anteriors utilitzant l'*RCommander*.

1. Importeu les dades del `data.frame` `classe` que heu creat abans (o bé directament), a l'*RCommander*.
2. Utilitzeu el menú

Datos → Modificar variables del conjunto de datos activo →
→ Calcular una nueva variable..


per afegir (crear) les noves variables IMC (recordeu posar l'altura en metres i el pes en kilos), `indicadoraA`, `indicadoraB` i `indicadoraC`, al document de dades actiu.

3. Utilitzeu els menus per a fer un estudi descriptiu complet de cadascuna de les variables categòriques del document de dades actiu.

Exercici 3.4. Preguntem a 25 persones, escollides a l'atzar a la plaça de Catalunya (BCN), quin és el diari que prefereixen llegir. Les categories són 1 (El Periódico), 2 (El Pais), 3 (L'Avui) i 4 (La Vanguardia). Les dades obtingudes són les següents:

3 4 1 1 3 4 3 3 1 2 2 1 4 4 4 3 2 1 2 1 3 3 1 4 2

Escriuiu totes les comandes d'R necessàries per a la realització del següent diagrama de barres:



Exercici 3.5. El creadors de pàgines web necessiten conèixer quins editors utilitzen els usuaris. La taula de sota conté els percentatges d'utilització segons les dades de la Societat Nord Americana de Geologia.

editor	percentatge
Explorer	86
Mozilla	4
Netscape	5
Opera	1
Altres	4

Realitzeu un diagrama de barres i un de sectors per a representar la informació de la taula, i escriuiu les comandes d'R que heu utilitzat.

Exercici 3.6. En aquest exercici volem repetir l'exercici anterior utilitzant l'**RCommander**.

- Introduïu les dades de la taula a l'**RCommander**.
- Utilitzeu el menú "Gráficas" per a fer el diagrama de barres i el de sectors.

Exercici 3.7. En aquest exercici volem repetir algunes de les taules de freqüències de la secció 2.3 utilitzant l'**RCommander**.

- Introduïu les dades de la variable "**errors**" a l'**RCommander**.
- Exploreu el menú Estadísticos → Resúmenes → practican sobre la variable "**errors**".

Exercici 3.8. Practiquem la construcció de noves variables a partir de la variable **NotaNum** de la secció 2.1. Utilitzeu les funcions **round** i **recode** per a construir les variables **Nota**, la nota obtinguda sense decimals, i **NotaCat**, la qualificació obtinguda: menor de 5, "S"; entre 5 i 7, "A"; de 7 a 9, "N" i major de 9, "E". Guardeu les tres variables en un fitxer que anomenarem **ExempleNotes.txt**.