

1	Estadística descriptiva d'una variable numèrica o quantitativa	2
1.1	Exemples de variables numèriques o quantitatives	2
1.2	Estadístics	3
1.3	Taules de freqüències agrupades	3
1.4	Gràfics	4
1.4.1	Histograma	4
1.4.2	Diagrama de caixa	5
2	Estadística descriptiva de dues variables	6
2.1	Dues variables numèriques: dades relacionades	6
2.2	Una variable numèrica i una categòrica: mostres independents	8
2.3	Dues variables categòriques	8
3	Exercicis	10

Part 1

Estadística descriptiva d'una variable numèrica o quantitativa

Ja vàrem veure que utilitzem el procediment categòric o qualitatiu si tenim certesa que el nombre de **valors diferents** presents en les dades no és elevat. En altre cas, usarem el procediment numèric o quantitatiu.

Recordeu que l'estadística descriptiva consisteix en la descripció de les dades mitjançant: estadístics, taules i gràfics, així com comentaris que contribueixen a caracteritzar les dades.

1.1 Exemples de variables numèriques o quantitatives

Un exemple senzill, dades corresponents a l'alçada dels individus de certa població:

```
>altura <- c(1.75, 1.80, 1.65, 1.90, 1.74, 1.91)
```

Useu el procediment numèric o quantitatiu. Fixeu-vos que gairebé tenim tants valors diferents com dades. Un altre exemple: Ja vàrem veure com la variable `NotaNum`, la nota amb decimals obtinguda per certs estudiants, s'havia de descriure amb el procediment numèric o quantitatiu. Tanmateix la variable `Nota`, corresponent a la nota obtinguda arrodonida, podia descriure's combinant els dos procediments.

```
>NotaNum<-c(10,10,10,10,10,9.9,9.9,9.9,9.9,9.8,9.8,9.7,9.6,9.4,9.2,9.1,9.1,9.9,
8.9,8.8,8.4,8.4,8.3,8,7.9,7.8,7.7,7.7,7.5,7.5,7.5,7.5,7.5,7.5,7.3,7.3,7.2,7.2,7,
6.9,6.8,6.7,6.4,6.2,6.2,6,5.9,5.9,5.7,5.6,5.6,5.6,5.6,5.6,5.5,5.4,5,5,5,4.9,4.9,
4.8,4.5,4.4,4.4,4.3,4.3,4.2,4.1,4,4,3.9,3.5,3.4,3.1,3.1,3.1,3,3,2.7,2.7,2.6,2.5,
2.3,2.2,2.2,2,2,1.9,1.8,1.7,1.2,1,0.3,0.2,0.1,0.1,0.1,0.1)
```

Per acabar amb els exemples, anem a explorar la llibreria `car`. Normalment una llibreria de funcions també conté taules de dades.

```
>library("car")
>data(package="car")
```

Aquí teniu un llistat dels conjunts de dades que conté el paquet i una breu descripció del contingut. Per exemple, exploreu els conjunts de dades: `Freedman` i `Womenlf`:

```
>help(Freedman)
>help(Womenlf)
```

Fixeu-vos que ens proporciona la descripció de les variables, les categories en cas que la variable sigui un *factor* i els articles relacionats.

Per últim, observeu els primers 10 casos de la taula **Freedman**

```
>Freedman[1:10,]
```

o bé

```
>head(Freedman)
```

1.2 Estadístics

Recordeu que la instrucció **summary** proporciona un resum dels estadístics bàsics en funció de la classe de la variable. Si la classe és **numeric** obtenim directament un resum d'estadístics força complet: mínim, primer quartil, mediana, mitjana, tercer quartil i màxim. No obstant trobem a faltar alguns estadístics. La desviació i la variància s'obtenen amb la funció **sd** i **var**, respectivament:

```
>summary(altura)
>sd(altura)
>var(altura)
```

També tenim instruccions específiques per a demanar cadascun dels estadístics. Per a la mida, el mínim, el màxim, la mediana i les quantiles tenim **length**, **min**, **max**, **median** i **quantile**, respectivament.

1.3 Taules de freqüències agrupades

Per a fer una taula de freqüències pel procediment numèric o quantitatiu caldrà distribuir les freqüències en intervals. En primer lloc cal fixar els intervals de classe i després procedir al recompte. Recordeu que els intervals de classe han de ser disjunts i la unió ha de contenir tots els possibles valors de la variable.

Considerem la variable **NotaNum**. Anem a construir uns intervals de classe. El R treballa amb intervals oberts per l'esquerra i tancats per la dreta. Per exemple, podríem considerar els intervals: (0, 2], (2, 4], (4, 6], (6, 8] i (8, 10], aleshores els punts de tall són: 0, 2, 4, 6, 8 i 10.

```
>talls<-c(0,2,4,6,8,10)
```

Ara podem procedir al recompte, per fer-ho primer convertim la variable **NotaNum** en una variable de classe **factor**, substituint cada valor de la variable per l'interval al qual pertany.

```
>NotaIntervals<-cut(NotaNum, talls)
>NotaIntervals
```

Fixeu-vos que podríem canviar les etiquetes de les categories usant el paràmetre **labels**

```
>cut(NotaNum, talls,
labels=c("menys de 2","entre 2 i 4","entre 4 i 6", "entre 6 i 8", "més de 8"))
```

Ara podem construir la taula de freqüències de la mateixa manera com havíem vist en el procediment categòric o qualitatiu usant aquestes categories que hem construït:

```
>summary(cut(NotaNum,talls))
```

Podríem guardar el resultat de tallar en intervals en una variable `NotaIntervals` per a simplificar les instruccions. Recordeu com obteníem la taula de freqüències completa:

```
>FreqAbs<-c(table(NotaIntervals))
>FreqAbsAcum<-cumsum(table(NotaIntervals))
>FreqRel<-c(table(NotaIntervals)/length(NotaIntervals))
>FreqRelAcum<-cumsum(table(NotaIntervals)/length(NotaIntervals))
>TaulaFreq<-data.frame(FreqAbs,FreqAbsAcum,FreqRel,FreqRelAcum)
>TaulaFreq
```

Us animem a explorar altres paràmetres de la funció `cut`.

1.4 Gràfics

Com ja hem vist, en l'estudi descriptiu d'un conjunt de dades és molt útil una bona representació gràfica que permeti veure, en un cop d'ull, el comportament de les dades. Hi ha molts tipus de representacions gràfiques. Per a una variable quantitativa, us proposem l'histograma i/o el diagrama de caixa. Tanmateix us animem a explorar-ne d'altres.

1.4.1 Histograma

Si fem el gràfic de barres que havíem vist al procediment categòric, aplicat a la taula de freqüències per intervals que acabem de fer, obtenim el que anomenem histograma. La diferència fonamental és que entre les barres no hi deixem espai. Així indiquem que correspon a freqüències d'intervals que provenen de fer l'agrupació d'una variable numèrica.

Tenim una funció específica per a fer-ho: **hist**. Aquesta funció distribueix en intervals i fa la representació gràfica:

```
>hist(NotaNum)
```

Per a veure els intervals que ha triat, podem fer:

```
>hist(NotaNum)$breaks
```

De fet, com tota funció del R, té altres resultats que podem consultar. Per a veure'ls fem:

```
>names(hist(NotaNum))
```

Fixeu-vos que hi ha el nom **breaks** que correspon als talls dels intervals i **count**, que correspon al recompte de cada interval.

Remarquem que fixats uns intervals, l'histograma correspon al gràfic de barres que ja havíem vist:

```
>barplot(summary(cut(NotaNum,talls)),space=0)
>hist(NotaNum, breaks=talls)
```

Us animem a explorar altres paràmetres de l'histograma:

```
>help(hist)
>hist(NotaNum, freq=TRUE)
```

Amb l'argument `freq=TRUE` fem que l'histograma tingui barres proporcionals a l'alçada, i l'eix vertical ens dona, com abans, la freqüència absoluta. Cal tenir en compte que quan els intervals no són iguals, això és gairebé sempre erroni, perquè no dona la impressió visual correcta. Es preferible que siguin les àrees de les barres, i no les alçades, les que siguin proporcionals a les freqüències. També podem insistir a posar `freq=FALSE` en el cas d'intervals iguals; la forma de l'histograma no canvia, però l'eix vertical dona "densities", de forma que l'àrea total és igual a 1. Moltes de les comandes gràfiques que hem vist per a `barplot` es poden usar en `hist`.

```
>hist(NotaNum, right=TRUE,
      density=10,
      angle=120,
      col="red",
      main="T'\{i}tol de l'histograma",
      sub="Subt'\{i}tol de l'histograma",
      xlab="Etiqueta eix horitzontal",
      ylab="Etiqueta eix vertical",
      axes=FALSE,
      border="blue")
```

1.4.2 Diagrama de caixa

Un altre diagrama interessant per a representar variables numèriques és el *diagrama de caixa*. La funció de R és `boxplot`:

```
>boxplot(NotaNum)
```

Us animem a explorar-ne els paràmetres:

```
>help(boxplot)
>boxplot(NotaNum, range=1.0,
        width=2,
        angle=120,
        col="red",
        border="blue",
        horitzontal=TRUE)
```

En un `boxplot` les dades estan representades en una escala vertical (llevat que hàgim establert `TRUE` pel paràmetre `horitzontal`). La línia central gruixuda representa la mediana. Els límits inferior i superior de la caixa són la primera i la tercera quartiles, respectivament. Les línies més curtes a baix i a dalt de tot són la més petita i més gran de les dades, entre les que cauen a una distància de `range=1.5` vegades l'alçada de la caixa.

Quan canvieu a `range=1`, les dades que ara cauen fora del rang entre les línies petites apareixen com un punt. Aquestes dades "fora de rang" se solen anomenar *valors exòtics* ("outliers" en anglès), i poden ser degudes a errors en la introducció de dades. Cal anar amb compte amb elles.

Naturalment, la consideració d'una dada com outlier, o no, depèn del valor de `range` que hem donat. Cal saber més coses sobre l'origen de les dades per a prendre decisions en aquest sentit. Si no es té més informació, és recomanable deixar-ho en el valor estàndard 1.5.

Part 2

Estadística descriptiva de dues variables

En aquesta part de la pràctica tractarem les eines bàsiques per a *comparar* o *descriure la relació* entre dues variables, en l'estadística descriptiva. La mecànica que s'utilitza per a relacionar o comparar dues variables, a nivell descriptiu, pot ser molt complexa. Vegem quins són els trets principals del procediment a seguir:

- En primer lloc cal establir el tipus de les variables, i.e. si són numèriques o categòriques (considerant també com a categòrica, una numèrica amb pocs valors diferents, si convé) i fer l'estadística descriptiva de cadascuna de les variables, per separat. Conèixer les variables per separat, ens pot ajudar molt a entendre la seva relació o a fer un estudi comparatiu.
- En segon lloc, cal decidir en quin dels següents tres casos ens trobem i procedir, en cada cas, tal i com s'explica en les següents seccions. Els tres casos que considerarem són:
 - 1) Les dues variables són numèriques i corresponen a mesures de tots i cadascun dels individus d'un mateix conjunt o població. En diem cas de "*dades relacionades*". Principalment, ens interessarà descriure llur relació.
 - 2) Les dues variables són numèriques i no hi ha (o no procedeix) relació entre els individus mesurats per cadascuna. En diem cas de "*mostres independents*". Principalment, ens interessarà comparar-les.
 - 3) Les dues variables són categòriques. Principalment, ens interessarà descriure la seva relació.

2.1 Dues variables numèriques: dades relacionades

Anem a veure alguns exemples d'aquesta situació. Les dades de pes i alçada que hem anat utilitzant en d'altres sessions.

```
>TaulaExemple<-data.frame(  
+pes=c(60,72,57,90,95,72),  
+altura=c(1.75,1.80,1.65,1.90,1.74,1.91))
```

Considereu ara les següents dades, corresponents a les longituds dels sèpals i els pètals d'una col·lecció d'exemplars de la planta *Virginia Iris*

```
>Virginia<-data.frame(  
+sepals=c(5.8,7.1,6.3,6.5,7.6,4.9,7.3,6.7,7.2,6.5,6.4,6.8,5.7,5.8,6.4,6.5,7.7),  
+petals=c(5.1,5.9,5.6,5.8,6.6,4.5,6.3,5.8,6.1,5.1,5.3,5.5,5.0,5.1,5.3,5.5,6.7))
```

Aquestes dades, naturalment, estan aparellades de manera que els valors que estan a la mateixa posició en els dos vectors, corresponen a la mateixa planta.

Per a descriure la relació entre dues variables, afegirem als estadístics que ja coneixeu la covariància i la correlació. Les corresponents instruccions amb R són `cov` i `cor`. Aquesta darrera calcula, per defecte, la correlació de Pearson (exploreu l'ajuda).

```
>cov(Virginia$sepals,Virginia$petals)
>cor(Virginia$sepals,Virginia$petals)
>cov(TaulaExemple$pes,TaulaExemple$altura)
>cor(TaulaExemple$pes,TaulaExemple$altura)
```

La representació gràfica bàsica per a descriure la relació entre dades aparellades és el *núvol de punts* o *diagrama de dispersió*, que podeu obtenir amb la funció `plot`:

```
>plot(TaulaExemple$pes,TaulaExemple$altura)
>plot(Virginia$sepals,Virginia$petals)
```

Un dels models més utilitzats per a descriure la relació entre dades aparellades és el *model de regressió simple*, que consisteix en relacionar-les mitjançant una recta: la recta de regressió o de mínims quadrats. Anem a dibuixar-la sobre el núvol de punts, utilitzant les fórmules que hem vist a teoria:

```
>b<-cov(Virginia$sepals, Virginia$petals)/var(Virginia$sepals)
>b
>a<-mean(Virginia$petals)-b*mean(Virginia$sepals)
>a
>plot(Virginia$sepals,Virginia$petals)
>abline(a,b)
```

La funció `abline`, justament, dibuixa la recta $y = a + bx$ sobre un gràfic ja existent. Com sabeu, b és el pendent de la recta, i a és el punt de l'eix vertical (o eix d'ordenades) per on passa la recta. Com és d'esperar, hi ha una manera més directa de calcular a i b amb R:

```
>lm(petals ~ sepals, data=Virginia)
>plot(Virginia$sepals,Virginia$petals)
>abline(lm(petals ~ sepals, data=Virginia))
```

Efectivament, obtenim directament els coeficients de la recta de regressió usant la funció `lm`

```
>lm(petals~sepals,data=Virginia)
>a<-lm(petals ~ sepals, data=Virginia)$coefficients[1]
>b<-lm(petals ~ sepals, data=Virginia)$coefficients[2]
>a;b;
```

Finalment, en aquesta situació de dades aparellades, sovint estem interessats en la diferència entre una variable i l'altre (sempre que estiguin mesurades en la mateixa unitat i tinguin sentit fer-ho). Un procediment que ja coneixem, i útil en aquest cas, és el següent:

```
>Virginia<-data.frame(Virginia, dif=Virginia$sepals-Virginia$petals)
>summary(Virginia$dif)
>hist(Virginia$dif)
>boxplot(Virginia$dif)
```

2.2 Una variable numèrica i una categòrica: mostres independents

Anem a veure alguns exemples d'aquesta situació. Suposem que volem comparar l'alçada d'homes i dones. En principi tenim dues variables numèriques: alçada dels homes (1.79, 1.80, 1.65, 1.87, 1.75, 1.74, 1.81) i alçada de les dones (1.56, 1.67, 1.72, 1.77, 1.64, 1.57). Ara bé, la manera correcta d'introduir aquestes dades és la següent:

```
>Taula<-data.frame(  
+altura=c(1.79,1.80,1.65,1.87,1.75,1.74,1.81,1.56,1.67,1.72,1.77,1.64,1.57),  
+sexe=c(rep("h",7),rep("d",6)))
```

On hem utilitzat una variable numèrica i una categòrica (anomenada “factor” o “variable de grup”).

La funció bàsica per a calcular estadístics d'una mostra per a cadascun dels nivells d'un factor, per separat, és `tapply`. Fixeu-vos com funciona:

```
>tapply(Taula$altura,Taula$sexe,mean)
```

I mireu quina manera més senzilla de fer un gràfic que ens compari els dos grups:

```
>boxplot(altura ~ sexe, data = Taula)
```

Per acabar vegem un darrer exemple on, utilitzant el que acabem de veure, comparem més de dos grups a la vegada:

```
>library(datasets)  
>summary(airquality$Ozone)  
>summary(airquality$Month)  
>tapply(airquality$Ozone,airquality$Month,length)  
>tapply(airquality$Ozone,airquality$Month,summary)  
>boxplot(Ozone ~ Month, data = airquality)
```

2.3 Dues variables categòriques

Quan tenim dues mesures categòriques (o numèriques amb pocs valors diferents), l'anàleg de la taula de freqüències és l'anomenada *taula de contingència* o *taula de doble entrada*. Pot passar que rebem les dades en forma de taula de contingència o bé que ens calgui fer-la. Per exemple, considerem les respostes a dues preguntes, que hem fet a 9 individus:

```
>dades<-data.frame(resposta1=c("a","b","a","a","a","b","a","a","b"),  
+resposta2=c(1,1,1,0,0,0,0,1,1))  
>taula<-table(dades$resposta1,dades$resposta2)  
>taula
```

Si tenim una taula de contingència i els valors de les cel·les són enters, podem recuperar un conjunt de dades equivalents a les inicials, de la següent manera:

```
>taula  
>dades1<-as.data.frame(taula)  
>class(dades1$Freq)  
>names(dades1)<-c("resposta1","resposta2","Freq")
```



```
>dades2<-dades1[rep(1:nrow(dades1),times = dades1$Freq),-3]
>rownames(dades2)<-1:nrow(dades2)
>dades2
```

Veiem un altre exemple. Tenim dades de dues variables, *lletra* i *color*, corresponents a les respostes obtingudes per certs individus a les preguntes: *Tria una lletra: a,b o c?* i *digues un color: blanc o negre?*. Cada entrada de la taula és la quantitat de dades que tenen un valor de *lletra* representat a la fila i un valor de *color* representat a la columna.

```
>taula<-matrix(c(5,7,3,1,0,8),byrow=TRUE, nrow=3)
>dimnames(taula)<-list(lletra=c("a","b","c"),color=c("blanc","negre"))
```

Addicionalment, podem obtenir les proporcions (freqüències relatives) de cada cel·la de la taula dins el total, de cada fila i cada columna, i les freqüències absolutes i relatives *marginals*, és a dir, de cadascuna de les variables per separat:

```
>prop.table(taula)
>prop.table(taula, 1)
>prop.table(taula, 2)
>margin.table(taula, 1)
>margin.table(taula, 2)
```

Finalment, veiem unes representacions gràfiques molt interessants:

```
>barplot(taula, main="Barplot de la Taula", legend=rownames(taula))
>barplot(prop.table(taula,2), main="Barplot de la Taula", legend=rownames(taula))
>mosaicplot(taula, main="Mosaic de la Taula")
```

El segon gràfic (anomenat “gràfic de barres escalat”) és molt útil per analitzar la dependència de les variables. El tercer gràfic representa la distribució conjunta.

Part 3

Exercicis

Exercici 3.1. *Observeu les variables dels conjunts de dades `Freedman` i `Womenlf`. Quines variables es poden descriure amb el procediment numèric o quantitatiu?*

Exercici 3.2. *Considereu el conjunt de dades sobre l'enfonsament del `Titanic` de la llibreria `datasets`. Utilitzeu l'ajuda per a veure informació sobre aquestes dades, descripció de les variables, etc.*

- 1) *Quina és la classe d'aquest conjunt de dades, com a objecte de `R`?*
- 2) *Reconstruiu un conjunt de dades equivalent a l'original, de la classe `data.frame`, i anomenau-lo `titan1`.*
- 3) *Feu un estudi descriptiu de cadascuna de les variables de `titan1`.*

Exercici 3.3. *Considereu ara el conjunt de dades sobre l'enfonsament del `Titanic` de la llibreria `carData`. Utilitzeu l'ajuda per a veure informació sobre aquestes dades, descripció de les variables, etc.*

- 1) *Quina és la classe d'aquest conjunt de dades a `R`?*
- 2) *Creeu-ne una còpia, de la classe `data.frame`, i anomenau-la `titan2`.*
- 3) *Feu un estudi descriptiu de cadascuna de les variables de `titan2`.*
- 4) *Quines diferències principals observeu entre `titan1` i `titan2`?*

Exercici 3.4. *Considereu la variable `Freedman$crime` del conjunt de dades `Freedman` i feu una taula de freqüències amb 6 intervals d'igual longitud.*

Exercici 3.5. *Els temps, en hores, de durada de 30 bateries fabricades per una certa empresa són:*

239	212	249	227	218	310	223	161	195	233	249	284	196	299	210
301	199	258	355	234	195	179	357	282	226	154	227	286	233	256

- a) *Feu una anàlisi descriptiva de la durada d'una bateria fabricada per aquesta empresa.*
- b) *Compareu els grups de bateries que duren més de 230 hores i les que duren menys.*

Exercici 3.6. L'any 1998 es va fer una enquesta per a conèixer les alçades de 66 alumnes de primer curs d'Informàtica. Es varen obtenir els resultats següents, expressats en centímetres:

Dones(43) 173, 170, 160, 173, 177, 160, 169, 170, 162, 156, 163, 175, 172, 167, 163, 160, 173, 170, 171, 175, 151, 173, 155, 164, 171, 165, 164, 150, 163, 157, 160, 164, 177, 158, 159, 166, 160, 170, 165, 178, 164, 156, 163

Homes(23) 189, 185, 181, 189, 180, 178, 185, 180, 174, 181, 169, 172, 181, 173, 183, 172, 190, 170, 172, 185, 178, 168, 167

- Calculeu els següents estadístics: mitjana, mediana, desviació estàndard i rang interquartílic per homes i dones separatament, i també per a totes les dades conjuntament.
- Feu els histogrames, primer per sexe i després per a totes les dades conjuntament. Comenteu els gràfics.
- Feu un diagrama de caixes per homes i dones. Compareu els grups (quin presenta més dispersió ?)

Exercici 3.7. Deu animals de laboratori van ser sotmesos a condicions que simulaven una certa malaltia. Es va enregistrar el seu ritme cardíac abans i després de l'experiment:

Animal	1	2	3	4	5	6	7	8	9	10
Abans	70	84	88	110	105	100	110	67	79	86
Després	115	148	176	191	158	178	179	140	161	157

Analitzeu descriptivament aquestes dades i utilitzeu els resultats per a respondre la següent pregunta: Les condicions experimentals simulades a l'experiment, augmenten el ritme cardíac dels animals estudiats?.

Exercici 3.8. Per estudiar si es podria reduir la dosi d'un fàrmac per a l'insomni es va fer una prova a 10 voluntaris. Un dia se'ls va subministrar la dosi normal del fàrmac i, al cap d'una setmana, se'ls va subministrar una dosi reduïda. En ambdues ocasions es van anotar les hores de son de les 10 persones:

Pacient	1	2	3	4	5	6	7	8	9	10
Dosi normal	6.5	5.3	7.2	5.4	8.1	7.8	5.6	5.9	7.1	6.9
Dosi reduïda	6.1	6.4	6.4	4.8	7.9	7.3	6.5	7.2	6.5	6.1

A nivell descriptiu, es pot aconsellar la reducció de la dosi sense disminuir l'eficàcia del fàrmac?

Exercici 3.9. Considereu el conjunt de dades **PlantGrowth** de la llibreria **datasets**.

- Quina és la mitjana i la desviació típica de la mida de les plantes tractades amb el primer tractament?
- Quin percentatge de plantes tractades amb el tractament 1 estan per damunt de la mediana del grup de control?
- Quin percentatge de plantes tractades amb el tractament 2 estan per damunt de la mediana del grup de control?
- Representeu gràficament les dades per a descriure i comparar la distribució de cadascun dels tres grups.
- A nivell descriptiu quin tractament sembla més efectiu?

Exercici 3.10. Considereu el conjunt de dades **iris** de la llibreria **datasets**.

- Feu una anàlisi descriptiva de la diferència entre la llargada dels sèpals i els pètals.
- Analitzeu la relació entre la llargada dels sèpals i els pètals: representeu la recta de regressió damunt del diagrama de dispersió. Calculeu els coeficients de la recta i el coeficient de correlació lineal de Pearson.
- Repetiteu l'apartat anterior per a cadascun dels grups definits per l'espècie.