

1	Distribucions Student i χ^2 de Pearson	2
1.1	La llei t -Student	2
1.2	La llei χ^2 de Pearson	3
2	Intervals de confiança	4
2.1	Intervals de confiança per a la mitjana	4
2.1.1	Amb normalitat i variància coneguda	4
2.1.2	Amb normalitat i variància desconeguda	6
2.1.3	El cas de mostres grans	7
2.2	Intervals de confiança per a la variància	7
2.3	Intervals de confiança per a una proporció	8
3	Tests d'hipòtesis paramètriques	9
3.1	Tests sobre la mitjana	9
3.2	Tests sobre proporcions	11
4	Tests d'hipòtesis no paramètriques basats en l'estadístic χ^2 de Pearson.	12
4.1	Tests de bon ajustament	12
4.2	Tests d'independència	13
4.3	Tests d'homogeneïtat	13
5	Exercicis	14

Part 1

Distribucions Student i χ^2 de Pearson

Hi ha dues lleis de probabilitat que encara no hem vist i que apareixen quan fem Estadística Inferencial. Es tracta de la llei t-Student i la llei khi al quadrat (χ^2) de Pearson. Anem a estudiar-les i a dibuixar-les.

1.1 La llei *t*-Student

Igual que amb totes les altres lleis de probabilitat, hi ha quatre funcions de R associades a la llei t-Student, que són:

```
>dt(x=0.4,df=10)
>pt(q=0.7,df=10)
>qt(p=0.90,df=10)
>rt(n=100,df=10)
```

l'argument **df** és el paràmetre de la t-Student, que s'anomena graus de llibertat i és un nombre enter positiu. El significat de les funcions i els seus paràmetres és l'anàleg al de totes les altres lleis de probabilitat que hem vist (repasseu-ho).

Per a dibuixar la densitat, anem a construir un vector amb tots els punts on volem avaluar-la, i usarem la funció **plot** aparellant cada punt amb el valor que dona la funció **dt**:

```
>punts<-seq(from=-4,to=4,by=0.01)
>plot(punts,dt(x=punts,df=3),type="l",ylim=c(0,0.5))
```

Hem dibuixat la densitat d'una llei *t*-Student amb 3 graus de llibertat. Afegirem al mateix gràfic diverses densitats, variant els graus de llibertat. S'afegeix un paràmetre de color a les següents instruccions, per a distingir cada densitat.

```
>lines(punts,dt(x=punts,df=10))
>lines(punts,dt(x=punts,df=30))
>lines(punts,dt(x=punts,df=100))
```

Afegiu també la densitat d'una llei normal $N(0; 1)$ amb un altre color encara.

```
>lines(punts,dnorm(x=punts,mean=0,sd=1))
```

Què s'observa?

1.2 La llei χ^2 de Pearson

Feu ara el mateix per a la llei χ^2 . Com que les variables amb aquesta llei només prenen valors positius, agafeu per exemple els punts de 0 a 10. La funció que dona la densitat en un punt és `dchisq` i les altres funcions canvien la primera lletra per p, q i r, com sempre. El paràmetre s'anomena també *graus de llibertat* i en R s'escriu `df`, igual que abans.

La importància de la llei χ^2 en Estadística rau en el fet que si tenim una mostra seguint una llei Normal $N(\mu; \sigma^2)$, l'estadístic

$$\frac{n-1}{\sigma^2} \hat{S}^2$$

on $\hat{S}^2$ és la variància mostral corregida, segueix una llei χ^2 amb $n-1$ graus de llibertat. Això es pot demostrar rigorosament, però també podem fer-ne una “comprovació experimental”. Simularem moltes vegades (100) una mostra de mida $n=30$ d'una llei normal $N(\mu=3; \sigma^2=4)$; de cada mostra, calcularem el valor de l'estadístic anterior; farem un histograma dels 100 valors obtinguts, i el superposarem a la densitat de la llei χ^2 amb $n-1=29$ graus de llibertat. El codi té diversos elements nous de R; vegeu els comentaris més avall.

```
>vmc<-c()  
>for(i in 1:100) vmc<-c(vmc,var(rnorm(mean=3,sd=2,n=30)))  
>estadistic<-29/4*vmc  
>punts<-seq(from=0,to=100,by=0.01)  
>plot(punts,dchisq(x=punts,df=29), type="l")  
>hist(estadistic,freq=FALSE,add=TRUE)
```

Comentaris:

- A la segona línia estem fent que el R repeteixi 100 vegades una instrucció. Cada vegada la instrucció podria ser diferent, perquè la variable `i`, que va canviant de valor, de 1 a 100, podria intervenir-hi; en aquest cas no ens cal. La instrucció en qüestió fa el següent: Simula una mostra de mida $n=30$ d'una variable aleatòria de llei normal amb mitjana $\mu=3$ i desviació tipus $\sigma=2$; calcula la variància corregida d'aquesta mostra; afegeix aquesta variància corregida al vector `vmc` i torna a dipositar el vector en `vmc`.
- A la primera línia s'inicialitza el vector `vmc`, sense cap element de moment.
- A la sisena línia hem usat l'argument `add=TRUE` de la funció `hist`. Aquesta opció fa que el dibuix de l'histograma s'afegeixi al plot anterior. En cas contrari, faria un gràfic nou. L'argument `add=TRUE` es pot usar en moltes funcions que dibuixen gràfics, però no en la funció `plot`.

Els experiments com l'anterior són més fiables com més gran sigui la quantitat de mostres que simulem. Si no us ha convençut gaire la semblança de l'histograma amb la densitat, podeu afegir 1000 valors més al vector `vmc` i dibuixar l'histograma resultant a sobre de l'anterior:

```
>for(i in 1:1000) vmc <- c( vmc, var( rnorm( mean=3, sd=2, n=30)))  
>estadistic <- 29/4 * vmc  
>hist( estadistic, freq=FALSE, add=TRUE,  
density=10, angle=45, col="red",  
breaks=seq( from=0, to=80, by=2))
```

Hem controlat el nombre de barres de l'histograma amb l'argument `breaks` perquè es vegi més clarament l'adaptació.

Part 2

Intervals de confiança

En aquesta secció treballarem l'estimació de la mitjana mitjançant intervals de confiança [*confidence intervals*], i a la vegada veurem més elements del llenguatge R. Els intervals de confiança pertanyen al camp de l'Estadística Inferencial [*Inferential Statistics*], és a dir la part de l'Estadística que tracta de treure conclusions sobre una població a partir de la informació subministrada per una mostra [*sample*] (una petita part de la població). Sempre suposarem que es tracta d'una mostra aleatòria simple, que vol dir que tots els individus de la població tenen la mateixa probabilitat de ser escollits cada cop que s'afegeix un individu a la mostra.

2.1 Intervals de confiança per a la mitjana

2.1.1 Amb normalitat i variància coneguda

Suposem que heu fet deu mesuraments independents d'una certa variable, que podem suposar que segueix una llei normal $N(\mu; \sigma^2 = 4)$. És a dir que coneixem la variància σ^2 , però no la mitjana μ , i el nostre objectiu és estimar-la mitjançant un interval de confiança a partir de la mostra de mesuraments obtinguda. Sabeu que per a tal fi s'utilitza l'estadístic

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

que segueix una llei $N(0,1)$ (vegeu l'exercici 5.8). Repasseu com es calcula l'interval usant aquest fet. Anem a fer-ho amb R, suposant que la mitjana mostral de les dades ha donat un valor de $\bar{x} = 5.4$ i que volem un interval amb nivell de confiança de 90%.

```
>mida<-10
>sigma<-2
>se<-sigma/sqrt(mida)
>niv.conf<-0.90
>xbarra<-5.4
>interval <- xbarra + qnorm( p=c((1-niv.conf)/2,(1+niv.conf)/2),mean=0,sd=1)*se
>print(interval)
```

Examinem el codi:

- Hem assignat primer els valors de mida de la mostra i de σ .
- A la tercera línia abreguem l'expressió $\frac{\sigma}{\sqrt{n}}$ (anomenada de vegades *error estàndard*, assignant-la a una variable.
- A les línies següents establim el nivell de confiança que volem i el valor de $\bar{x}$ que hem obtingut a la mostra.

- A la línia cinquena construïm l'interval. En primer lloc, necessitem les quantiles de la $N(0; 1)$ corresponents a les probabilitat 0.05 i 0.95.
- Finalment imprimim els dos extrems de l'interval.

Podeu guardar aquest codi com una funció per usar-la més endavant. Guardeu el següent codi en un fitxer d'extensió "R".

```
IntConfN<-function(mida,sigma,niv.conf,xbarra)
{
  se<-sigma/sqrt(mida)
  interval <- xbarra + qnorm(p=c((1-niv.conf)/2,(1+niv.conf)/2),mean=0,sd=1)*se
  print(interval)
}
```

Per exemple, el podem anomenar: "IntConfN.". Ara, des de la consola, el podeu carregar fent:

```
source("IntConfN.R")
```

I l'executem fent:

```
>IntConfN(mida=10,sigma=2,niv.conf=0.90,xbarra=5.4)
```

Sabeu que si volem un nivell de confiança més alt ens sortirà un interval més gran, i que si la mida de la mostra és més gran, l'interval es reduirà. Això es dedueix fàcilment de les fórmules, però podeu veure-ho amb el programa anterior. Proveu diversos valors de niv.conf (0.90, 0.95, 0.99, . . .) i de mida de la mostra (10, 100, 1000, . . .).

```
>#variem el nivell de confiança
>IntConfN(mida=10,sigma=2,niv.conf=0.90,xbarra=5.4)
>IntConfN(mida=10,sigma=2,niv.conf=0.95,xbarra=5.4)
>IntConfN(mida=10,sigma=2,niv.conf=0.99,xbarra=5.4)
>#variem la mida de la mostra
>IntConfN(mida=10,sigma=2,niv.conf=0.90,xbarra=5.4)
>IntConfN(mida=100,sigma=2,niv.conf=0.90,xbarra=5.4)
>IntConfN(mida=1000,sigma=2,niv.conf=0.90,xbarra=5.4)
```

Un interval de confiança amb nivell de confiança 0.90, a la llarga "atrapa" el vertader valor del paràmetre μ que volem estimar, el 90% de les vegades. Podem fer-ne la comprovació experimental: Generem 100 mostres de mida $n = 16$ d'una llei $N(\mu = 0; \sigma^2 = 1)$. Per a cada mostra, farem l'interval de confiança amb nivell 0.90 i mirarem quants cops el vertader valor del paràmetre (que és 0) queda dins de l'interval. Per tal de visualitzar-ho farem una representació gràfica dels 100 intervals.

El següent codi ens servirà per a generar les 100 mostres i calcular els intervals corresponents:

```
>mostres<-100
>mida<-16
>niv.conf<-0.90
>intervals<-matrix(0,2,mostres) # conté els extrems dels intervals
>i<-0
>while (i<m) {
```

```

i<-i+1
mitjana<-mean(rnorm(mida))
intervals[,i]<-mitjana+qnorm(c(0.5*(1-niv.conf),0.5*(1+niv.conf)))*sqrt(1/mida)
}

```

I per a la representació gràfica utilitzarem la següent funció:

```

>interval.plot <- function(intervals,NC){
  L <- intervals[1,]; U <- intervals[2,]
  n <- length(L)
  si <- (intervals[1,]<=0 & intervals[2,]>=0)
  encerts <- sum(si)
  NC <- niv.conf
  plot(L,type="n",ylim=c(-1.5,1.5),xlab=paste(encerts,"intervals, de 100,
  contenen la mitjana.")
  ,ylab=" ",main=paste("Simulació d'Intervals de Confiança per a la
  mitjana de N(0,1) \n Nivell de confiança: ", "(1-\u03B1)", "=", NC))
  segments((1:n)[L<0 & U>0], L[L<0 & U>0],(1:n)[L<0 & U>0],U[L<0 & U>0])
  segments((1:n)[L>0],L[L>0],(1:n)[L>0],U[L>0],col="red",lwd=2.5)
  segments((1:n)[U<0],L[U<0],(1:n)[U<0],U[U<0],col="red",lwd=2.5)
  abline(h=0,col="blue")}

```

I l'executem fent:

```

>interval.plot(intervals,niv.conf)

```

Observacions:

- La variable **encerts** anirà comptant les vegades que atrapem el paràmetre.
- El **while** executa el conjunt d'instruccions incloses entre les claus fins que es deixa de complir la condició ($i < m$).
- Els arguments de la funció **interval.plot()** són una **matriu** i un **nombre real**.
- La comanda de R **matplot()**, que ja hem utilitzat a l'exercici 4.12 (al mòdul 4) i que en cert sentit és més simple, també podria servir per a fer una representació gràfica similar a l'anterior. Proveu-ho!

2.1.2 Amb normalitat i variància desconeguda

Tenim una mostra de mida $n = 9$ dels pesos de diversos paquets d'un cert producte comercial. Podem suposar que els pesos segueixen una llei Normal $N(\mu; \sigma^2)$. Hem obtingut una mitjana mostral $\bar{x} = 244.2$ grams i el que volem tenir és un interval de confiança per a la mitjana teòrica μ , amb nivell de confiança 0.95. No sabem quin el valor de σ^2 , com és habitual a la pràctica real. Per tant, usarem l'estadístic

$$\frac{\bar{X} - \mu}{\hat{s}/\sqrt{n}}$$

on $\hat{s}$ és la desviació típica mostral corregida. Sabem que aquest estadístic segueix una llei t -Student amb $n - 1$ graus de llibertat. Endemés hem obtingut de la mostra $\hat{s} = 8.23$ grams.

Per a calcular aquest interval de confiança ho farem com abans. La diferència principal és que en lloc d'usar la funció **qnorm** haurem d'usar **qt**. La resta és similar.

```

>mida<-9
>sbarret<-8.23
>se<-sbarret/sqrt(mida)
>niv.conf<-0.95
>xbarra<-244.2
>interval <- xbarra + qt(df=mida-1, p=c((1-niv.conf)/2,(1+niv.conf)/2))*se
>print(interval)

```

2.1.3 El cas de mostres grans

Quan la llei de la variable amb la que estem tractant no és una llei Normal, però la mida mostral és gran, se solen fer intervals per a l'esperança usant els mateixos estadístics que per al cas Normal. El resultat no és exacte, però l'aproximació és més bona com més gran és la mida de la mostra. Això es basa en el fet que, si anomenem μ a l'esperança, l'estadístic

$$\frac{\bar{X} - \mu}{\hat{s}/\sqrt{n}}$$

segueix aproximadament una llei $N(0,1)$ quan la mida de la mostra n és gran, per a qualsevol llei inicial de la variable X . Anem a fer una comprovació experimental, usant la llei Binomial. Simularem mostres de mida 30 d'una binomial de paràmetres $n = 20$ i $p = 0.5$; farem 1000 mostres i de cadascuna calcularem el valor de l'estadístic i dibuixarem l'histograma d'aquests valors superposat a la densitat de $N(0,1)$.

```

>estadistic<-c()
>for (i in 1:1000)
>{
>mostra<-rbinom(size=20,prob=0.5,n=30)
>xbarra<-mean(mostra)
>sbarret<-sd(mostra)
>estadistic<-c(estadistic,(xbarra-20*0.5)/(sbarret/sqrt(30)))
>}
>punts<-seq(from=-4,to=4,by=0.01)
>plot(punts,dnorm(mean=0,sd=1,x=punts),type="l")
>hist(estadistic,freq=FALSE,add=TRUE)

```

Als exercicis 5.8 i 5.9 es continua aquesta comprovació experimental, mitjançant la simulació, del fenomen d'aproximació per la distribució normal de les distribucions de les variables que són sumes (d'un nombre relativament gran) de variables, com és el cas de les mitjanes de mostres relativament grans. Aquest fenomen s'anomena, d'una forma genèrica, “teorema central del límit” (TCL) en la Teoria de la Probabilitat.

2.2 Intervals de confiança per a la variància

L'últim interval de confiança interessant sobre els paràmetres d'una llei Normal és el de la variància σ^2 , essent la mitjana μ desconeguda. S'utilitza l'estadístic

$$\frac{n-1}{\sigma^2} \hat{S}^2$$

que segueix una llei χ^2 de Pearson amb $n - 1$ graus de llibertat. Supposeu que teniu una mostra de mida $n = 16$ d'unes certes mesures, amb la qual s'ha obtingut una variància mostral corregida $\hat{s}^2 = 2.18$. Observant el que hem fet fins ara, feu un programa que calculi un interval de confiança per a σ^2 , amb nivell 0.90. El resultat que us ha de donar és [1.308220, 4.503547].

2.3 Intervals de confiança per a una proporció

L'estimació per intervals es pot fer per a qualsevol paràmetre que ens interressi estimar. És cert que trobar-los de forma analítica (com hem fet fins ara) no sempre és possible. Veiem un darrer cas: l'interval de confiança per una proporció. Suposem que tenim una moneda trucada i volem estimar quina és la probabilitat d'obtenir "cara", diem p aquesta probabilitat. Podríem fer molts llançaments i estimar aquesta probabilitat amb el promig de "cares" que observem, això seria l'estimació puntual, $\hat{p}$. Quan n és gran, l'estimació de p per interval es pot fer utilitzant el següent estadístic (vegeu el cas de mostres grans, que hem comentat anteriorment):

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1 - \hat{p})/n}}$$

que segueix (aproximadament) una llei normal amb mitjana 1 i variància 0. Remarquem que n és el nombre de llançaments que hem fet per estimar p . Aquest interval el podem calcular de la mateixa manera que hem fet fins ara. Per exemple, suposem que hem fet 100 llançaments i hem obtingut 70 cares

```
>mida<-100
>pbarret<-70/100
>niv.conf<-0.95
>interval<-pbarret
+qnorm(p=c((1-niv.conf)/2,(1+niv.conf)/2))*sqrt(pbarret*(1-pbarret)/mida
>print(interval)
```

Aquest procediment és pràcticament equivalent (però no coincident) al que s'obté amb la funció de R `prop.test( )`

```
prop.test(70,100,conf.level=0.95)$conf.int
```

Si la mida de la mostra no és prou gran l'aproximació per la normal no és gaire bona. En aquest cas tenim a l'abast altres procediments més adequats, basats en mètodes exactes. Per exemple, suposem que hem fet 10 llançaments i hem obtingut 7 cares:

```
>binom.test(7,10,conf.level=0.95)$conf.int
```

Observeu les diferències provant amb diferents valors dels arguments.

Part 3

Tests d'hipòtesis paramètriques

Farem alguns tests d'hipòtesis utilitzant les funcions que incorpora R. Observareu que quan disposem d'un paquet estadístic, solem concloure el test utilitzant el **p-value**, enlloc del valor de l'estadístic. La regla general per a concloure un test usant el **p-value** és:

Si $\text{p-value} < \alpha$ acceptem H_1

essent H_0 la hipòtesi nul·la natural i H_1 la hipòtesi alternativa (també anomenada “hipòtesi de recerca”). Observem que decidir acceptar H_1 , i per tant rebutjar H_0 , no equival a provar que H_1 és certa (o que H_0 sigui falsa). Només vol dir que la mesura de l'evidència estadística expressada per les dades, “contra” la hipòtesi nul·la, ha resultat prou gran com per a poder prendre aquesta decisió, amb una probabilitat d'equivocar-nos inferior a α .

3.1 Tests sobre la mitjana

Farem tests d'hipòtesis sobre la mitjana utilitzant les dades de l'exemple 3.4.1 del llibre de R. Delgado. Recordem que les dades corresponen a 10 mesuraments de la concentració de mercuri en una mostra de condensat de gas comercial, en ng/ml:

23.3, 22.5, 21.9, 21.5, 19.9, 21.3, 21.7, 23.8, 22.6, 24.7

Se suposa que el nivell de referència que determina el límit de toxicitat alta per causa del mercuri està fixat en 24 ng/ml. Volem veure si la mesura d'evidència estadística “contra” la hipòtesi (nul·la) d'alta toxicitat és, o no, suficientment gran com per a poder rebutjar-la, i per tant acceptar que ens trobem en una situació de toxicitat més baixa.

I això ho volem fer suposant que les dades són una mostra d'observacions independents d'una variable X , amb distribució normal $N(\mu, \sigma^2)$, amb mitjana μ i variància σ^2 desconegudes.

El test el podem plantejar així:

$$\begin{cases} H_0 : & \mu \geq 24 \\ H_1 : & \mu < 24 \end{cases}$$

Sabem que en aquest test s'utilitza l'estadístic:

$$\frac{\bar{X} - \mu}{\hat{s}/\sqrt{n}}$$

on $\hat{s}$ és la desviació tipus mostral corregida, que sabem que segueix una llei t -Student amb $n - 1$ graus de llibertat. Vegem com ho fa R.

La funció que s'utilitza s'anomena **t.test()**. Feu **help(t.test)** per a obrir la pàgina d'ajuda d'aquesta funció, que mirarem diverses vegades en el que segueix.

Posem les dades en el vector **concent** i apliquem la funció **t.test()**:

```
>concent <- c(23.3, 22.5, 21.9, 21.5, 19.9, 21.3, 21.7, 23.8, 22.6, 24.7)
>t.test(concent,mu=24,alternative="less")
```

Hem especificat en primer lloc el vector de dades, després el valor de la hipòtesi nul·la (24), i finalment la direcció de l'alternativa (més petit que 24). El resultat dóna diversos elements d'informació. Concretament, i en aquest ordre, veiem:

- El nom del vector de dades (data:).
- El valor de l'estadístic ($t =$), els graus de llibertat de la llei t-Student que segueix l'estadístic ($df =$), i el p-valor obtingut ($p\text{-value} =$).
- Verbalització de la hipòtesi alternativa (alternative hypothesis:)
- Un interval de confiança unilateral (o fita superior de confiança per a la mitjana) (95 percent confidence interval:)
- La mitjana mostral (mean of x).

Observeu que a la pàgina de l'ajuda de la funció `t.test()`, aquesta sortida apareix descrita a l'apartat **Value**. Concretament, diu que la funció `t.test()` retorna una llista amb nou components, i ens dóna el nom de tots ells. Per exemple, si feu:

```
>my_test<-t.test(concent,mu=24,alternative="less")
>my_test$estimate
>my_test$statistic
>my_test$p.value
```

esteu accedint als components individuals de la llista. Això és útil si el test és un pas dins d'un programa. Ens fixarem ara en els arguments de la funció `t.test()`. A la pàgina d'ajuda, apartat **Usage**, veiem el “prototipus” o “plantilla” de la funció.

A la plantilla veiem els noms dels arguments. També veiem que alguns noms van seguits d'uns valors; per exemple, $\mu = 0$. Recordeu que aquests són els valors “per defecte” si no especifiquem l'argument. I que si no hi ha un valor “per defecte” assignat, per exemple en el cas de x , aleshores és obligatori especificar aquest argument.

A l'ajut, sota l'epígraf **Arguments** està explicat què volen dir els arguments. Veiem que y és un vector numèric que té “per defecte” el valor NULL. Aquest és un valor especial que indica que no prendrà cap valor “per defecte”, però que no és obligatori especificar-lo. En canvi x , el vector de les dades sobre el que es farà el test, sí és obligatori.

El valor “per defecte” de **alternative** sembla ser triple i, per tant, esperaríem que si no l'especifiquem ens faci tres tests diferents, un per a cada valor de l'argument, però no és així.

Anem ara a fer la interpretació del resultat del test. La mitjana mostral pren el valor $\bar{x} = 22.32$. És a dir que, en mitjana, la concentració de mercuri és inferior a 24, el valor fixat com a límit de referència. És raonable, doncs, preguntar-se si aquest resultat dóna prou evidència, o no, “contra” la hipòtesi nul·la de toxicitat alta.

Per una banda, la mitjana sembla que ho indica, i per un bon marge. Però per altra banda, la mostra es bastant petita. Podria ser que el resultat observat sigui degut purament a l'atzar? El fet que es vegi una considerable dispersió en les dades (i fins i tot algun valor superior al límit!) també contribueix a fer pensar que la diferència de 1.68 ng/ml pot ser casual.

Per ajudar a decidir en aquesta disjuntiva és pel que es fan tests d'hipòtesis. Concretament ens hem de fixar en el p -valor. El p -valor ens indica quina és la probabilitat d'equivocar-nos si donem per bona la

hipòtesi alternativa. En el nostre cas, tenim un p -valor de 0.001926. Això vol dir que si proclamem que el nivell de mercuri és de toxicitat “no alta”, la probabilitat que ens estiguem equivocant al fer aquesta afirmació és 0.001926.

Aleshores, què decidim davant d’aquest resultat? Tot depèn del risc que vulguem assumir. Aquesta tolerància al risc es pot concretar mitjançant el nivell de significació, i.e.: la màxima probabilitat d’equivocar-nos que volem assumir.

Per exemple, si fixem un nivell de significació de 0.001, decidirem que ens quedem amb la hipòtesi nul·la (no tenim prou evidència “contra” la situació d’alta toxicitat), perquè el p -valor és més gran que 0.001 (pràcticament el doble!).

En canvi, si fixem el nivell de significació en 0.01, haurem de decidir que ens quedem amb la hipòtesi alternativa (tenim prou evidència “contra” la situació d’alta toxicitat), perquè el p -valor és més petit que 0.01 (pràcticament la cinquena part!).

Fixeu-vos bé que el que proclamem amb la hipòtesi alternativa és que el nivell de concentració de mercuri està per sota del límit de referència d’alta toxicitat, sense dir quant per sota. Per exemple, si el que volem és afirmar que la concentració de mercuri es troba 1.5ng/ml per sota del nivell de referència, aleshores el test és diferent. Cal especificar $\mu=22.5$. Què us sembla que li passarà al p -valor si poseu aquesta hipòtesis nul·la? Serà més gran o més petit? Comproveu-ho!.

3.2 Tests sobre proporcions

Suposem que de 100 persones, escollides a l’atzar, 42 responen favorablement a la qüestió plantejada. Ens preguntem si aquest resultat dóna suport a l’hipòtesi de que la veritable proporció poblacional de gent favorable és 50%?

Ho plantegem com un test d’hipòtesis. En aquest cas H_0 és $p = 0.5$ i H_1 , la hipòtesi alternativa, és $p \neq 0.5$, que és una alternativa de tipus bilateral. Per tant tenim el test:

$$\begin{cases} H_0 : & p = 0.5 \\ H_1 : & p \neq 0.5 \end{cases}$$

Quan es tracta d’un test per a una sola proporció, del tipus anterior (o bé amb H_1 unilateral), R permet fer un test exacte (sense passar per l’aproximació per la llei Normal), mitjançant la funció `binom.test()`:

```
> binom.test(x=48,n=100,p=0.5,alternative="two.sided")
```

També es pot fer el test aproximat que es fa habitualment a mà, de la següent manera (observeu la petita diferència en els p -valors.):

```
> prop.test(x=48,n=100,p=0.5,alternative="two.sided")
```

Ara suposem que, en lloc de 100 persones, n’entrevistem 1000. I suposem que els favorables són 420. Això ens dóna més, o menys, evidència “contra” la hipòtesi (nul·la)? Tracteu d’esbrinar-ho!

Part 4

Tests d'hipòtesis no paramètriques basats en l'estadístic χ^2 de Pearson.

Els tests de bon ajustament, d'independència o d'homogeneïtat no són com els tests sobre paràmetres que hem vist fins ara. No es tracta de decidir sobre un paràmetre d'una distribució, sinó de decidir si la distribució pertany a una determinada família de distribucions.

Tots tres tests es basen en un estadístic molt similar, que segueix una llei χ^2 de Pearson. Per això, de vegades s'anomenen tests de la χ^2 . A R es fan tots amb la mateixa funció: `chisq.test()`.

4.1 Tests de bon ajustament

Sospitem que un dau de parxís no està ben equilibrat. El llancem cent vegades i fem una taula de freqüències dels resultats, obtenint les freqüències absolutes 20, 24, 15, 21, 12, 8 pels valors 1, 2, 3, 4, 5 i 6, respectivament. El dau és equilibrat si la probabilitat de cada cara és $1/6$.

El test el podem plantejar així:

$$\begin{cases} H_0 : & \text{El dau és equilibrat} \\ H_1 : & \text{El dau no és equilibrat} \end{cases}$$

A R podem fer el test introduint les dades de la següent manera:

```
> freq = c(20,24,15,21,12,8)
> chisq.test(freq)
```

Amb un nivell de significació del 5% hauríem d'admetre que el dau pot ser equilibrat, però per poc. Plantegem ara el següent test:

$$\begin{cases} H_0 : & p_1 = 0.15, p_2 = 0.14, p_3 = 0.15, p_4 = 0.15, p_5 = 0.15, p_6 = 0.26 \\ H_1 : & \text{Les probabilitats de les cares del dau no són les anteriors} \end{cases}$$

En aquest cas cal introduir les dades de la següent manera:

```
> freq = c(20,24,15,21,12,8)
> probabilitats=c(0.15,0.14,0.15,0.15,0.15,0.26)
> chisq.test(freq,p=probabilitats)
```

Podem extreure els valors esperats i els residuals corresponents a cadascuna de les cares. Feu-ho consultant l'ajut de la funció `chisq.test()`. Quin és el valor de la suma dels quadrats dels residuals?

4.2 Tests d'independència

Com a exemple de test d'independència usarem les dades `HairEyeColor` contingudes en el package `datasets` que R carrega en arrencar. Escriviu el nom a la consola i veureu que les dades consisteixen en un array 3-dimensional (i.e.: una taula de triple entrada), on apareixen les freqüències absolutes de les combinacions de les característiques “color d’ulls”, “color de cabell” i “gènere”. S’han distingit quatre valors qualitatius per a la primera variable, quatre també per a la segona, i dos per a la tercera. R ens mostra dues taules de doble entrada, separant segons la tercera variable.

Voldríem fer un test sobre la independència del color d’ulls i el color del cabell, sense distingir gènere. Plantegem el test de la següent manera:

$$\begin{cases} H_0 : & \text{Color d’ulls i color del cabell són independents} \\ H_1 : & \text{Color d’ulls i color del cabell no són independents} \end{cases}$$

Per això, primer sumarem les dades dels dos gèneres, per obtenir una sola taula de doble entrada que ens doni la distribució marginal bidimensional corresponent a les dues variables: color d’ulls i color del cabell. Després només cal posar-la com a únic argument a la funció `chisq.test()`.

```
>taula<-HairEyeColor[ , , 1]+HairEyeColor[ , , 2]
>chisq.test(taula)
```

Observem que, pel càlcul de la distribució marginal, també podríem haver utilitzat la funció `fTable()`, de la següent manera:

```
> ftable(HairEyeColor, row.vars = 1, col.vars = 2)
```

Observem també que, sempre que apliquem la funció `chisq.test()` a una taula de contingència de doble entrada, R fa el test χ^2 de Pearson pel contrast de la hipòtesi nul·la que les dues variables són independents, “contra” l’alternativa que no ho són.

Es pretén esbrinar si la hipòtesi nul·la és, o no, compatible amb les observacions. Què diríeu en aquest cas concret?

4.3 Tests d’homogeneïtat

El test χ^2 de Pearson admet moltes aplicacions diferents. Una d’elles és el contrast de l’hipòtesi d’homogeneïtat de diferents poblacions. Com exemple veurem com podem fer el test d’homogeneïtat proposat a l’exemple 5.3.5 del llibre de R.Delgado. En aquest cas podem plantejar el test:

$$\begin{cases} H_0 : & p_1 = p_2 = p_3 = p_4 \\ H_1 : & \text{Les proporcions } p_1, p_2, p_3, p_4 \text{ no són iguals} \end{cases}$$

Introduïm les dades a R i apliquem la funció `chisq.test()`, com abans:

```
>taula<-cbind(c(12,15,25,17),c(8,5,15,13))
>chisq.test(taula)
```

Observeu que el resultat és el mateix si utilitzem la funció `rbind()` en lloc de `cbind()`:

```
>taula2<-rbind(c(12,15,25,17),c(8,5,15,13))
>chisq.test(taula2)
```

Compareu el resultat amb el del llibre.

Part 5

Exercicis

Exercici 5.1. *Dibuixeu la densitat de la χ^2 per graus de llibertat 1,2,3,4,5, sobre un mateix gràfic. Proveu de guardar el gràfic en PDF i en Jpeg i, si no ho heu fet mai, obriu-los amb un altre programa, i observeu la diferència al fer zoom.*

Exercici 5.2. *Calculeu l'interval de confiança, amb nivell de confiança 0.9, per a la proporció de fallida de cert component informàtic si de 1000 ordinadors ha fallat en 21.*

Exercici 5.3. *Compareu el procediment estudiat a la secció 2.1.2 amb la següent comanda de R:*

```
t.test( )$conf.int
```

Obteniu els mateixos resultats?

Exercici 5.4. *Executeu les següents comandes. Interpreteu les comandes (què fa cadascuna d'elles?) i comenteu els resultats observats.*

```
> x=rnorm(100);y=rt(100,9)
> boxplot(x,y)
```

Exercici 5.5. *Executeu les següents comandes. Interpreteu les comandes (què fa cadascuna d'elles?) i comenteu els resultats observats.*

```
> xvalors=seq(-4,4,.01)
> plot(xvalors,dnorm(xvalors),type="l",col="red")
> for(i in c(2,6,12,20,50)) points(xvalors,dt(xvalors,df=i),type="l",lty=i)
```

Exercici 5.6. *Simuleu 100 mostres de mida $n = 10$ d'una llei $N(\mu = 5, \sigma^2 = 4)$. Per a cada mostra, trobeu l'interval de confiança amb nivell 0.90 i comenteu quants cops el vertader valor del paràmetre (que és 5) queda dins de l'interval.*

Exercici 5.7. *Executeu les següents comandes. Interpreteu les comandes (què fa cadascuna d'elles?) i comenteu els resultats observats.*

```
> m = 50; n=20; p = .5;
> pbarret = rbinom(m,n,p)/n
> SE = sqrt(pbarret*(1-pbarret)/n)
> alpha = 0.10;z = qnorm(1-alpha/2)
> matplot(rbind(pbarret - z*SE, pbarret + z*SE), rbind(1:m,1:m),type="l",lty=1)
> abline(v=p)
```

Exercici 5.8. En aquest exercici farem simulacions amb nombres aleatoris que il·lustrin el significat del Teorema Central del Límit, en el cas normal.

1. Obriu un nou arxiu de dades i simuleu 10 columnes de longitud 100 de nombres aleatoris que tinguin una distribució normal de mitjana $\mu = 42$ i variància $\sigma^2 = 36$. Guardeu els resultats en les variables anomenades $X_1, X_2, \dots, X_{10}$.

Per a fer això, anomenant `simulnormal` al conjunt de dades:

```
>simulnormal<-data.frame(matrix(rnorm(1000,mean=42,sd=6),ncol=10))
```

Observeu que el símbol `<-` assigna a l'objecte de nom `simulnormal` una `data.frame` (és a dir, una graella). Aquesta graella està formada pels valors de la funció `rnorm` que assigna valors aleatoris (1000) seguint una distribució normal de mitjana 42 i desviació 6 repartits en 10 columnes.

Ara interpretarem cada fila com una mostra de grandària $n = 10$ d'una variable aleatòria que té distribució $\mathcal{N}(42, 6)$. D'aquesta manera tenim simulades 100 mostres de grandària 10, totes provinents de la variable X distribuïda en forma normal de mitjana poblacional $\mu = 42$ i variància poblacional $\sigma^2 = 36$.

2. Calculeu la mitjana mostral de cada fila i guardeu el resultat en una columna anomenada `xbarra`. Això és un exercici de transformació d'una variable.
3. Construïu un histograma de la variable `xbarra`.
4. Com s'interpreten les dades de la variable `xbarra`?

Exercici 5.9. Ara es farà un estudi similar per a una distribució diferent de la normal, que és el cas que ens interessa especialment en les aplicacions als intervals de confiança (secció 2.1.3 i 2.3).

1. Obriu un nou arxiu de dades i simuleu 6 columnes de longitud 500 de nombres aleatoris que tinguin una distribució uniforme en l'interval $(0, 6)$. Guardeu els resultats en les variables anomenades $X_1, X_2, \dots, X_6$.

Per a fer això, anomenant `simulunif` al conjunt de dades:

```
>simulunif<-data.frame(matrix(runif(3000,min=0,max=6),ncol=6))
```

2. Calculeu les mitjanes de les files per a les grandàries mostrals $n = 2, 3, 4, 5, 6$. Guardeu les mitjanes tal com s'indica a continuació:

La mitjana de	Guardar amb el nom	Correspon a
X_1, X_2	$X_{1.2}$	mitjana de 1-2
X_1, X_2, X_3	$X_{1.3}$	mitjana de 1-3
X_1, X_2, X_3, X_4	$X_{1.4}$	mitjana de 1-4
X_1, X_2, X_3, X_4, X_5	$X_{1.5}$	mitjana de 1-5
$X_1, X_2, X_3, X_4, X_5, X_6$	$X_{1.6}$	mitjana de 1-6

3. Construïu els histogrames per a cadascuna de les variables $X_1, X_{1.2}, X_{1.3}, X_{1.4}, X_{1.5}, X_{1.6}$. Compareu aquests histogrames i presteu atenció al canvi que es va produint en aquests histogrames.

4. Per a cadascuna de les variables $X1, X1.2, X1.3, X1.4, X1.5, X1.6$, compareu els valors mostrals de la mitjana i de la variància amb els valors teòrics corresponents.

Observeu que quan demaneu un histograma desapareix l'anterior, per evitar-ho en el primer histograma que genereu seleccioneu

→ Historico → Grabando

llavors genereu els altres histogrames i amb les tecles d'avançar o retrocedir pàgina podreu passar d'uns als altres.

5. Interpreteu els resultats obtinguts.

Exercici 5.10. Cadascuna de 20 cordes de llargària 1 metre es talla per un punt, escollit aleatòriament i independent i amb distribució uniforme entre els seus extrems, de manera que en resulten dos trossos. Tot seguit, escollim el tros més petit de cadascuna i els ajuntem, obtenint una nova corda amb llargària aleatòria.

Trobeu una aproximació de la probabilitat que la nova corda, obtinguda amb l'experiment anterior, tingui una llargària superior a 6 metres, de les dues següents maneres:

- Fent una simulació de l'experiment amb R.
- Utilitzant el teorema central del límit per aproximar la distribució de la llargària de la nova corda, mitjançant una distribució normal adient.

Exercici 5.11. Quan es comparen variàncies (fent quocients) apareixen, de manera natural, les anomenades distribucions F (de Fisher-Snedecor). Són molt útils en l'aplicació de la metodologia ANOVA (d'anàlisi de la variància).

La distribució $F(n,m)$ és, per definició, la distribució del quocient de dues variables, X i Y , estadísticament independents, amb distribucions χ^2 de Pearson amb n i m graus de llibertat, cadascuna d'elles dividida pels seus graus de llibertat:

$$\frac{X/n}{Y/m}$$

- Busqueu les funcions de R que serveixen pel càlcul de probabilitats i de les quantiles de les distribucions F de Fisher.
- Determineu z sabent que $\mathbb{P}\{F_{(20,15)} \leq z\} = 0.95$
- Determineu z sabent que $\mathbb{P}\{F_{(15,20)} > z\} = 0.95$
- Busqueu les funcions de R que serveixen pel càlcul de les funcions de densitat de probabilitat de les distribucions F.
- Representeu gràficament la funció de densitat de les distribucions $F(15,20)$ i $F(20,15)$.
- Busqueu les funcions de R que serveixen per a la generació de mostres aleatòries de les distribucions F de Fisher.
- Genereu una mostra de mida 1000 de la distribució $F(15,20)$ i compareu l'histograma amb la funció de densitat, superposant els dos gràfics en un de sol.

Exercici 5.12. Feu el programa pel càlcul d'un interval de confiança per a la variància d'una distribució $N(\mu, \sigma^2)$, amb mitjana desconeguda, que es demana a la secció 2.2. Què caldria modificar en el cas que la mitjana fòra coneguda?

Exercici 5.13. Els pesos d'una mostra de 8 gossos de raça gos d'atura polonès de Podhale eren, en Kg: 58, 50, 60, 65, 64, 62, 56 i 57. Suposant normalitat en els pesos, es demana:

- Podem dir que la mitjana dels pesos és inferior a 61Kg, amb una probabilitat d'equivocar-nos del 5%?
- I que és inferior a 62 Kg?
- I a 60 Kg?
- Contesteu les mateixes preguntes, però amb una probabilitat d'equivocar-nos del 10%.

Exercici 5.14. En un cert estudi es té una mostra de 140 pacients asmàtics, dels quals el 35% van tenir reaccions positives a la pell davant la presència de pols.

- Podem dir que la proporció de pacients asmàtics amb al·lèrgia a la pols és menor que 0.4, amb una probabilitat d'equivocar-nos del 5%?
- I que és més gran que 0,3?
- Contesteu les mateixes preguntes, però amb una probabilitat d'equivocar-nos del 10%.

Exercici 5.15. Genereu una mostra aleatòria d'una moneda trucada, en la qual la probabilitat d'obtenir cara és de 0.7

- Considereu la mostra de mida 10. Apliqueu el test de bon ajustament per a decidir, amb risc d'equivocar-nos del 1%, si la moneda està trucada.
- Repetiu la pregunta anterior amb una mostra de mida 100.

Exercici 5.16. Considereu el conjunt de dades sobre el Titanic de la llibreria `datasets`.

```
> library(datasets)
> TitanicDF<-as.data.frame(Titanic)
> TitanicDF<-TitanicDF[rep(1:nrow(TitanicDF),times = TitanicDF$Freq),]
> summary(TitanicDF)
```

Usant les dades del Titanic, podeu afirmar que hi ha relació entre ser “supervivent” i ser “dona”, amb risc d'equivocar-nos del 5%?

```
> table.prop(table(TitanicDF$Survived,TitanicDF$Sex),2)
> barplot(table.prop(table(TitanicDF$Survived,TitanicDF$Sex),2),legend.text=T)
```

Exercici 5.17. Un gran nombre d'ordinadors, que utilitza certa multinacional, han estat utilitzats durant els últims dos anys per usuaris inexperts. Es realitza un estudi per a descobrir si hi ha relació entre l'usuari i la necessitat de restaurar el sistema operatiu després de 2 anys.

	Restaurat	No restaurat
Inexpert	52	248
No inexpert	48	272

- Feu un gràfic de barres apilat i escalat al 100% per tal de decidir, a nivell descriptiu, si hi ha relació.
- Feu un test per a prendre la decisió, assumint un risc del 5%.

Exercici 5.18. Simuleu el llançament d'un dau just (i.e. simètric) 200 vegades i també el d'un dau trucat, amb probabilitats $p_1 = \frac{1}{12}$, $p_2 = \frac{1}{12}$, $p_3 = \frac{1}{6}$, $p_4 = \frac{1}{6}$, $p_5 = \frac{1}{6}$ i $p_6 = \frac{1}{3}$, 100 vegades. Estudieu si el test d'homogeneïtat χ^2 de Pearson detecta la diferència dels dos daus, en base als resultats observats dels 300 llançaments.

Exercici 5.19. *El conjunt de dades UCBAmissions, contingudes en el package `datasets` que R carrega en arrencar, conté dades sobre les admissions a la UC Berkeley, per gènere i departament. Volem esbrinar si la distribució dels homes admesos és similar a la de les dones admeses. Utilitzeu la funció `fable()` per a extreure les dades necessàries i feu un test d'homogeneïtat de les distribucions. Repetiu el test pel grup d'estudiants rebutjats (i.e.: no admesos). A quines conclusions arribeu? Es podria dir que hi ha una certa discriminació, per gènere, en les admissions a aquesta universitat americana?*