

Tema 0. Eines per a una estadística computacional

R, RStudio/Posit, Quarto, GitHub i fluxos de treball reproduïbles

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

De les dades al codi, del codi als resultats, dels resultats a una decisió

Per què un tema 0?

- ▶ En aquesta assignatura no només farem càlculs: també aprendrem a **treballar amb dades**.
- ▶ L'objectiu és que cada resultat sigui:
 - traçable,
 - reproduïble,
 - comunicable,
 - i fàcil de revisar.
- ▶ Això és especialment important en informàtica: dades, scripts, versions i informes han de conviure.

Idea central

**Estadística = dades +
probabilitat + codi +
interpretació**

Missatge pràctic

El codi que no es pot reproduir és difícil de validar.

Objectius de la sessió

Al final d'aquest tema hauríeu de poder:

1. Obrir un projecte d'RStudio/Posit de manera ordenada.
2. Crear i executar un script senzill en R.
3. Importar dades i generar una primera taula o gràfic.
4. Preparar un informe breu amb Quarto.
5. Fer servir Git i GitHub per lliurar una pràctica reproducible.
6. Entendre per què la simulació i la computació paral·lela apareixeran al llarg del curs.

No és un curs de programació avançada

És una introducció al **flux de treball computacional** que farem servir per aprendre estadística.

Treball local

- ▶ R: llenguatge per a càlcul estadístic.
- ▶ RStudio/Posit: entorn de treball.
- ▶ Quarto: informes amb text, codi i resultats.

Treball amb versions

- ▶ Git: historial de canvis.
- ▶ GitHub: repositori remot i lliuraments.


Paquets d'R

- ▶ tidyverse: manipulació i visualització.
- ▶ readr: lectura de fitxers.
- ▶ ggplot2: gràfics.
- ▶ future, furrr: paral·lelització.

Durant el curs

No cal memoritzar totes les funcions: cal aprendre a construir un procés net i verificable.

Flux de treball recomanat



Principi de reproduïbilitat

Una altra persona hauria de poder obtenir els mateixos resultats executant el vostre codi en el mateix projecte.

R com a calculadora estadística

```
# Operacions bàsiques
2 + 3
sqrt(16)
log(100)

# Objectes
x <- c(12, 15, 13, 18, 20)
mean(x)
sd(x)
summary(x)
```

- ▶ En R assignem valors amb `<-`.
- ▶ Un vector és una col·lecció de valors.
- ▶ Moltes funcions estadístiques bàsiques ja estan incorporades.

Bon hàbit

Comenteu el codi amb `#`: ajuda a entendre què esteu fent.

Primer exemple: temps d'execució

```
set.seed(123)

temps_ms <- c(31, 29, 34, 30, 35, 33, 32, 80)

mean(temps_ms)
median(temps_ms)
sd(temps_ms)
summary(temps_ms)
```

Pregunta estadística

Quin és un temps típic d'execució? Hi ha algun valor sospitós?

- ▶ La mitjana és sensible a valors extrems.
- ▶ La mediana pot ser més robusta.
- ▶ La desviació típica mesura variabilitat.

Dades en format taula

```
library(tidyverse)

bench <- tibble(
  algorisme = c("A", "A", "A", "B", "B", "B"),
  mida = c(1000, 5000, 10000, 1000, 5000, 10000),
  temps_ms = c(8, 40, 85, 6, 29, 62)
)

bench
```

Una fila = una observació

Cada fila representa una execució o mesura.

Una columna = una variable

Per exemple: algorisme, mida de l'entrada, temps d'execució.

Una primera visualització

```
ggplot(bench, aes(x = mida, y = temps_ms,  
                  color = algorisme)) +  
  geom_point(size = 3) +  
  geom_line() +  
  labs(  
    x = "Mida de l'entrada",  
    y = "Temps d'execució (ms)",  
    color = "Algorisme"  
  ) +  
  theme_minimal()
```

- ▶ Els gràfics ajuden a detectar patrons.
- ▶ En informàtica són útils per estudiar rendiment.
- ▶ El codi genera el gràfic: no cal copiar-lo manualment.

Connexió amb el curs

La descriptiva bivariant començarà precisament amb relacions entre dues variables.

Què és un projecte?

Una carpeta que conté tot el necessari per a una anàlisi:

- ▶ dades,
- ▶ scripts,
- ▶ informes,
- ▶ resultats,
- ▶ historial de versions.

Estructura recomanada

```
estadistica-ei/  
  data/  
  R/  
  reports/  
  figures/  
  README.md  
  practica0.qmd
```

Regla pràctica

Eviteu rutes absolutes com `/home/usuari/Escriptori/...` Feu servir camins relatius dins del projecte.

Llegir dades

```
library(tidyverse)

logs <- read_csv("data/logs_servidor.csv")

glimpse(logs)
summary(logs)
```

Exemples de dades del curs

- ▶ Logs de servidor.
- ▶ Temps d'execució.
- ▶ Resultats de simulacions.
- ▶ Errors de transmissió.
- ▶ Peticions per segon.

Important

No modifiqueu manualment les dades originals: creeu scripts que facin la neteja.

Quarto: informes reproduïbles

Un informe Quarto combina

- ▶ text explicatiu,
- ▶ codi en R,
- ▶ taules,
- ▶ gràfics,
- ▶ conclusions.

Per què és útil?

Si canvien les dades o el codi, l'informe es pot tornar a generar automàticament.

Lliuraments

Les pràctiques poden contenir el fitxer `.qmd`, el codi, les dades i el resultat en HTML o PDF.

Un fragment mínim de Quarto

```
---  
title: "Pràctica 0"  
author: "Nom Cognoms"  
format: html  
---  
  
## Objectiu  
Analitzem els temps d'execució d'un algoritme.  
  
```{r}  
temps <- c(31, 29, 34, 30, 35, 33, 32, 80)
summary(temps)
```\n\n## Comentari  
La mediana és menys sensible al valor extrem que la mitjana.
```

Què resol Git?

- ▶ Guardar l'historial del projecte.
- ▶ Recuperar versions anteriors.
- ▶ Saber què ha canviat.
- ▶ Treballar de forma ordenada.

Sense Git

```
practica.R  
practica_final.R  
practica_final_bona.R  
practica_final_bona2.R
```

Amb Git

Un fitxer, amb historial de canvis.

Cicle bàsic amb Git

```
git status  
git add practica0.qmd R/analisi.R  
git commit -m "Afegeix primera anàlisi descriptiva"  
git push
```

1. Miro l'estat del projecte.
2. Marco els fitxers que vull guardar.
3. Faig una fotografia del projecte.
4. La pujo a GitHub.

Missatges de commit

Han de descriure el canvi, no només dir "canvis".

Què aportarà GitHub al curs?

- ▶ Repositoris per a pràctiques.
- ▶ Historial de lliuraments.
- ▶ README amb instruccions.
- ▶ Possibilitat de revisar codi.

Un bon repositori conté

- ▶ README.md: què fa el projecte.
- ▶ data/: dades necessàries.
- ▶ R/: scripts.
- ▶ reports/: informe final.
- ▶ commits clars i ordenats.

Exemple de README

```
# Pràctica 0: temps d'execució
```

```
Objectiu: analitzar descriptivament els temps d'execució  
simulats de dos algoritmes.
```

```
## Fitxers
```

- data/temps_algoritmes.csv: dades d'entrada
- R/analisi.R: codi principal
- reports/practica0.qmd: informe reproducible

```
## Com reproduir els resultats
```

1. Obrir el projecte a RStudio.
2. Executar reports/practica0.qmd.

Simulació: una idea que apareixerà sovint

```
set.seed(2026)

# Simulem 1000 temps de resposta en ms
temps <- rnorm(n = 1000, mean = 120, sd = 15)

mean(temps)
quantile(temps, c(.05, .50, .95))
```

- ▶ La simulació ens ajuda a entendre fenòmens aleatoris.
- ▶ Permet experimentar sense tenir encara dades reals.
- ▶ Serà central en probabilitat, inferència i bootstrap.

Reproduïbilitat

`set.seed()` fa que una simulació es pugui repetir.

Exemple: simular peticions a un servidor

```
set.seed(123)

# Nombre de peticions per segon
peticions <- rpois(n = 60, lambda = 2.5)

tibble(segon = 1:60, peticions = peticions) |>
  ggplot(aes(x = segon, y = peticions)) +
  geom_col() +
  theme_minimal()
```

Pregunta

Quina és la probabilitat de tenir més de 5 peticions en un segon?

- ▶ Aquest exemple connecta amb la distribució de Poisson.
- ▶ També connecta amb capacitat, rendiment i cues.

Per què parlar de computació paral·lela?

Moltes tasques estadístiques són repetitives

- ▶ 10.000 simulacions Monte Carlo.
- ▶ 5.000 mostres bootstrap.
- ▶ Comparar molts paràmetres.
- ▶ Avaluar molts escenaris.

Idea

Si les repeticions són independents, sovint podem repartir-les entre diversos nuclis del processador.

En aquest curs

Ho veurem només de manera introductòria i aplicada.

Primer tast de paral·lelització amb R

```
library(future)
library(furrr)

plan(multisession, workers = 4)

simula_mitjana <- function(i) {
  x <- rnorm(10000, mean = 0, sd = 1)
  mean(x)
}

resultats <- future_map_dbl(1:1000, simula_mitjana)

mean(resultats)
sd(resultats)
```

Lectura del codi

Fem 1000 simulacions independents i les distribuïm entre diversos processos.

Bones pràctiques des del primer dia

Codi

- ▶ Noms de variables clars.
- ▶ Comentaris breus i útils.
- ▶ Scripts ordenats per blocs.
- ▶ Cap resultat copiat manualment.

Projecte

- ▶ Carpeta estructurada.
- ▶ Fitxers amb noms informatius.
- ▶ README actualitzat.
- ▶ Commits freqüents i descriptius.

Objectiu

Que una altra persona pugui entendre què heu fet sense preguntar-vos-ho.

Eviteu

- ▶ Codi només a la consola.
- ▶ Fitxers sense estructura.
- ▶ Rutes absolutes.
- ▶ Gràfics enganxats manualment.
- ▶ No fer commits fins al final.

Feu

- ▶ Scripts i informes reproduïbles.
- ▶ Projectes d'RStudio.
- ▶ Camins relatius.
- ▶ Taules i gràfics generats amb codi.
- ▶ Commits petits i freqüents.

Tasques

1. Instal·lar o comprovar R, RStudio/Posit, Git i Quarto.
2. Crear un repositori a GitHub per a l'assignatura.
3. Crear un projecte d'RStudio/Posit connectat al repositori.
4. Escriure un script que simuli o llegeixi dades de temps d'execució.
5. Crear un informe practica0.qmd amb una taula, un gràfic i una interpretació breu.
6. Fer alguns commits i pujar-los a GitHub.