

Estadística descriptiva univariant

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

Dades, codi, visualització, simulació i reproduïbilitat

Per què començar per descriptiva univariant?

- ▶ Abans de modelitzar, predir o programar un algoritme, cal **mirar les dades**.
- ▶ La descriptiva univariant respon preguntes bàsiques:
 - Quins valors apareixen?
 - Quin és un valor típic?
 - Hi ha molta variabilitat?
 - Hi ha valors estranys o errors?
- ▶ En informàtica això apareix en **logs**, **benchmarks**, **latència**, **errors**, **memòria** i **experiments A/B**.

Idea clau

Una variable no és només una columna:
és una història sobre un sistema.

Dades → Resum → Gràfic
→ Interpretació → Decisió

Objectius del tema

Al final d'aquest tema hauríeu de poder:

1. Reconèixer el tipus d'una variable i escollir el resum adequat.
2. Construir taules de freqüències i gràfics amb R.
3. Calcular i interpretar mitjana, mediana, moda, variància, desviació típica, quartils i percentils.
4. Detectar asimetria, valors atípics i possibles errors de registre.
5. Preparar un petit informe reproduïble amb RStudio/Posit, Quarto i GitHub.

Enfocament computacional

No farem només càlculs manuals: aprendrem a **automatitzar**, **visualitzar** i **documentar** l'anàlisi.

El flux de treball que farem servir



Eines

- ▶ R per calcular.
- ▶ RStudio/Posit per treballar per projectes.
- ▶ Quarto per fer informes.
- ▶ GitHub per versionar i lliurar.

Bones pràctiques

- ▶ Codi curt i llegible.
- ▶ Dades separades del codi.
- ▶ Resultats regenerables.
- ▶ Commits amb missatges informatius.

Tipus de variables: exemples informàtics

Qualitatives

- ▶ **Nominals**: sistema operatiu, navegador, estat d'una petició OK/ERROR, tipus d'usuari.
- ▶ **Ordinals**: prioritat baixa/mitjana/alta, severitat d'un bug, nivell de risc.

Quantitatives

- ▶ **Discretes**: nombre d'errors, peticions per minut, commits per setmana.
- ▶ **Contínues**: latència, temps d'execució, ús de memòria, temperatura d'un sensor.

Pregunta recurrent

El fet que una variable estigui codificada amb números no vol dir necessàriament que sigui quantitativa.

La matriu de dades

- ▶ Les **files** són casos o observacions.
- ▶ Les **columnes** són variables.
- ▶ La mida mostral és el nombre de files: n .
- ▶ Cada columna ha de tenir un significat i unes unitats clares.

id	navegador	estat	mida	temps_ms
1	Chrome	OK	gran	118
2	Firefox	OK	petit	74
3	Chrome	ERROR	mitjà	312
4	Safari	OK	gran	141
5	Chrome	OK	petit	69

Exemple: registre simplificat de peticions a una aplicació web.

Llegir dades amb R

```
library(tidyverse)

logs <- read_csv("data/logs_api.csv")

glimpse(logs)
summary(logs$temps_ms)
```

Objectiu

Passar d'un fitxer de dades a un objecte que podem explorar, resumir i representar gràficament.

Freqüència absoluta i relativa

Per una variable amb valors $x_1, \dots, x_k$:

Freqüència absoluta

n_i = nombre d'observacions amb valor x_i

$$\sum_{i=1}^k n_i = n$$

Freqüència relativa

$$f_i = \frac{n_i}{n}$$

$$\sum_{i=1}^k f_i = 1$$

Interpretació

Les freqüències relatives permeten comparar mostres de mides diferents.

Taules de freqüències amb R

```
# Freqüències absolutes
freq_abs <- table(logs$estat)

# Freqüències relatives
freq_rel <- prop.table(freq_abs)

freq_abs
freq_rel
```


estat	n_i	f_i
OK	824	0.824
ERROR	176	0.176

Pregunta

És acceptable una taxa d'error del 17.6%? Depèn del context i del sistema.

Representació de variables qualitatives

- ▶ Per variables qualitatives fem servir sobretot **diagrames de barres**.
- ▶ El diagrama de sectors pot ser útil amb poques categories, però sovint és menys informatiu.
- ▶ En informàtica interessa veure ràpidament quina categoria domina.



Gràfic de barres amb ggplot2

```
library(tidyverse)

ggplot(logs, aes(x = navegador)) +
  geom_bar() +
  labs(
    title = "Peticions per navegador",
    x = "Navegador",
    y = "Nombre de peticions"
  )
```

Missatge metodològic

El codi del gràfic ha de formar part de l'informe. Això permet reproduir exactament el resultat.

Freqüències acumulades

Per variables numèriques ordenables:

$$N_i = n_1 + n_2 + \cdots + n_i, \quad F_i = \frac{N_i}{n}.$$

Aplicació informàtica

Si X és el temps de resposta d'una API, $F(200)$ pot interpretar-se com:


proporció de peticions amb temps de resposta ≤ 200 ms.

Pregunta útil

Quin percentatge de peticions compleix el llindar de qualitat del servei?

Histogrammes: forma de la distribució

- ▶ Per variables quantitatives contínues, l'histograma resumeix la distribució.
- ▶ Cal escollir un nombre d'interval·ls o *bins*.
- ▶ Massa pocs interval·ls amaguen informació; massa interval·ls afegeixen soroll.



Histograma amb R

```
ggplot(logs, aes(x = temps_ms)) +  
  geom_histogram(bins = 30) +  
  labs(  
    title = "Distribució dels temps de resposta",  
    x = "Temps de resposta (ms)",  
    y = "Nombre de peticions"  
  )
```

Experiment ràpid

Canvieu `bins = 10`, `bins = 30` i `bins = 80`. Canvia la història que explica el gràfic?

Compte amb els intervals de diferent amplada

- ▶ Si tots els intervals tenen la mateixa amplada, podem dibuixar alçades proporcionals a les freqüències.
- ▶ Si els intervals tenen amplades diferents, l'àrea del rectangle ha de ser proporcional a la freqüència.
- ▶ Altrament podem obtenir una representació visualment enganyosa.

Regla pràctica

En un histograma, el que importa és l'**àrea**, no només l'alçada.

Mitjana

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Valor d'equilibri. Sensible a valors extrems.

Mediana

Valor central un cop ordenades les dades. Robusta davant d'extrems.

Moda

Valor més freqüent. Molt útil en variables qualitatives o discretes.

En dades computacionals

Temps de resposta, mida de fitxers i ús de memòria poden tenir cues llargues. La mediana sovint és més informativa que la mitjana.

Mitjana i mediana amb valors extrems

Execució	1	2	3	4	5	6	7
Temps A (ms)	98	101	99	100	102	97	103
Temps B (ms)	98	101	99	100	102	97	620

Sistema A

$$\bar{x} = 100, \quad Md = 100$$

Sistema B

$$\bar{x} = 174, \quad Md = 100$$

Interpretació

Un sol valor extrem pot canviar molt la mitjana, però no necessàriament la mediana.

```
logs %>%  
  summarise(  
    n = n(),  
    mitjana = mean(temps_ms),  
    mediana = median(temps_ms),  
    minim = min(temps_ms),  
    maxim = max(temps_ms)  
  )
```

Bona pràctica

No doneu només un número. Doneu també el context: unitats, mida mostral i possibles valors atípics.

Quan la mitjana pot enganyar

Exemple clàssic: sous

Quatre programadors cobren 1000€ i el propietari 6000€.

$$\bar{x} = \frac{4 \cdot 1000 + 6000}{5} = 2000$$

Exemple informàtic: latència

Moltes peticions responen en 100 ms, però algunes fallen i triguen 2 s.

mitjana > mediana

Missatge

Sempre que hi hagi asimetria o valors extrems, compareu mitjana i mediana.

Mesures de dispersió

- ▶ Les mesures de centre no són suficients: dos sistemes poden tenir la mateixa mitjana i variabilitat molt diferent.
- ▶ La dispersió indica com d'inestables o heterogènies són les observacions.

Variància corregida


$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Desviació típica

$$s = \sqrt{s^2}$$

Té les mateixes unitats que les dades.

Mateixa mitjana, diferent estabilitat



Pregunta

Quin sistema preferiríeu per a una aplicació en temps real?

Dispersió amb R

```
logs %>%  
  summarise(  
    mitjana = mean(temps_ms),  
    variancia = var(temps_ms),  
    desviacio = sd(temps_ms),  
    rang = max(temps_ms) - min(temps_ms),  
    cv = sd(temps_ms) / mean(temps_ms) * 100  
  )
```

Coeficient de variació

$$CV = \frac{s}{\bar{x}} \times 100$$

Serveix per comparar variabilitat relativa entre variables o sistemes amb escales diferents.

Percentils i quartils

- ▶ El percentil p és un valor que deixa aproximadament un $p\%$ de les observacions per sota.
- ▶ La mediana és el percentil 50.
- ▶ Els quartils divideixen les dades en quatre parts:

$$Q_1 = P_{25}, \quad Q_2 = P_{50} = Md, \quad Q_3 = P_{75}.$$

- ▶ El rang interquartílic és

$$RI = Q_3 - Q_1.$$

En sistemes informàtics

El percentil 95 o 99 de la latència pot ser més important que la mitjana.

Quantils amb R

```
quantile(logs$temps_ms, probs = c(0.25, 0.50, 0.75, 0.95, 0.99))
```

P25	P50	P75	P95	P99
82	106	148	310	870

Lectura


El 99% de les peticions responen en 870 ms o menys. L'1% restant pot ser crític.

Diagrama de caixa: detectar valors atípics

- ▶ Resumeix mediana, quartils, rang interquartílic i possibles valors atípics.
- ▶ Barreres internes:

$$Q_1 - 1.5RI, \quad Q_3 + 1.5RI.$$

- ▶ Els punts fora d'aquest interval són candidats a **outliers**.



Boxplot amb R

```
ggplot(logs, aes(y = temps_ms)) +  
  geom_boxplot() +  
  labs(  
    title = "Diagrama de caixa dels temps de resposta",  
    y = "Temps de resposta (ms)"  
  )
```

Ampliació natural

Comparar per grups:

```
ggplot(logs, aes(x = navegador, y = temps_ms)) + geom_boxplot()
```

- ▶ Una distribució és simètrica si la seva forma és semblant a banda i banda del centre.
- ▶ L'asimetria positiva és habitual en temps de resposta: moltes observacions petites i unes poques molt grans.
- ▶ L'asimetria negativa és menys habitual en latències, però pot aparèixer en notes, puntuacions o percentatges limitats superiorment.


Coeficient d'asimetria

$$As = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

Senyal pràctic

Si $\bar{x} > Md$, sovint hi ha cua a la dreta.

Distribució simètrica i asimètrica



Interpretació

La forma de la distribució ajuda a decidir quines mesures resum són més informatives.

Simular per entendre

```
set.seed(2026)

# Temps de resposta artificials: molts valors petits i alguns grans
temps <- c(rnorm(950, mean = 100, sd = 20),
           rnorm(50, mean = 500, sd = 80))

mean(temps)
median(temps)
sd(temps)
quantile(temps, c(.50, .95, .99))
```

Per què simular?

La simulació permet construir exemples controlats i veure com canvien els estadístics quan canvia el sistema.

Primer contacte amb càlcul repetit

```
set.seed(2026)

resultats <- replicate(1000, {
  x <- rnorm(100, mean = 100, sd = 20)
  mean(x)
})

summary(resultats)
sd(resultats)
```

Idea per més endavant

Quan repetim molts càlculs, podem plantejar-nos paral·lelitzar-los. La descriptiva és també una porta d'entrada a la simulació computacional.

Exemple: versió paral·lelitzable

```
library(future)
library(furrr)

plan(multisession, workers = 4)

resultats <- future_map_dbl(1:1000, function(i) {
  x <- rnorm(100, mean = 100, sd = 20)
  mean(x)
})
```

Missatge

La idea estadística és la mateixa; el que canvia és com repartim el càlcul entre nuclis o processos.

Estructura recomanada

Carpeta/fitxer	Contingut
data/	dades originals
R/	scripts auxiliars
figures/	gràfics generats
informe.qmd	informe reproduïble
README.md	descripció del projecte

Commits útils

- ▶ afegeix lectura de dades
- ▶ calcula taula de freqüències
- ▶ afegeix histograma de latència
- ▶ interpreta valors atípics