

Estadística descriptiva bivariant

Relacions entre variables, taules, gràfics i primers models

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

Dues variables, una pregunta: hi ha relació?

Per què descriptiva bivariant en informàtica?

- ▶ Molts problemes computacionals no depenen d'una sola variable.
- ▶ Volem entendre **relacions** entre variables:
 - navegador i estat d'una petició,
 - sistema operatiu i tipus d'error,
 - mida de l'entrada i temps d'execució,
 - càrrega del servidor i latència,
 - nombre d'usuaris i consum de memòria.
- ▶ La descriptiva bivariant és el pas previ a la inferència, la regressió i el machine learning.

Idea clau

Descriure dues variables és buscar patrons, dependències i anomalies en un sistema.

Variable A + Variable
B → Relació → In-
terpretació → Decisió

Objectius del tema


Al final d'aquest tema hauríeu de poder:

1. Construir i interpretar taules de contingència.
2. Calcular freqüències marginals, relatives i condicionades amb R.
3. Visualitzar relacions entre dues variables qualitatives.
4. Construir i interpretar núvols de punts per a dues variables numèriques.
5. Calcular covariància, correlació i recta de regressió.
6. Interpretar prediccions i residus amb prudència.
7. Documentar l'anàlisi en un informe reproduïble amb codi i resultats.

Enfocament computacional

Les fórmules són importants, però també ho és saber convertir-les en codi fiable, gràfics clars i conclusions útils.

Mapa del tema



Pregunta transversal

Quan veiem una associació, és real, és rellevant, és lineal, és causal o és un artefacte de les dades?

Dues variables qualitatives: taula de contingència

Considerem dues variables qualitatives:

- ▶ A amb modalitats $A_1, A_2, \dots, A_k$.
- ▶ B amb modalitats $B_1, B_2, \dots, B_\ell$.

	B_1	B_2	$\dots$	B_ℓ
A_1	n_{11}	n_{12}	$\dots$	$n_{1\ell}$
A_2	n_{21}	n_{22}	$\dots$	$n_{2\ell}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
A_k	n_{k1}	n_{k2}	$\dots$	$n_{k\ell}$

Interpretació


n_{ij} és el nombre d'observacions que tenen simultàniament la modalitat A_i i la modalitat B_j .

Exemple informàtic

A = navegador, B = estat de la petició: OK, timeout, error 500.

Exemple: peticions web per navegador i estat

Navegador	OK	Timeout	Error	Total
Chrome	820	25	35	880
Firefox	430	18	22	470
Safari	260	12	28	300
Edge	210	15	25	250
Total	1720	70	110	1900



Lectura ràpida

La major part de peticions són correctes, però la proporció d'errors no és igual en tots els navegadors.

Freqüències marginals

Les freqüències marginals són els totals de files i columnes.

Marge dret

$$n_{i.} = \sum_{j=1}^{\ell} n_{ij}$$

Freqüència total de la modalitat A_i .

Marge inferior

$$n_{.j} = \sum_{i=1}^k n_{ij}$$

Freqüència total de la modalitat B_j .

En l'exemple

Hi ha 880 peticions de Chrome i 110 peticions amb error. La grandària total és $n = 1900$.

Freqüències relatives

Les freqüències relatives s'obtenen dividint per la grandària total n :

$$f_{ij} = f(A_i \cap B_j) = \frac{n_{ij}}{n}, \quad f_{i.} = \frac{n_{i.}}{n}, \quad f_{.j} = \frac{n_{.j}}{n}.$$

Per què són útils?

- ▶ Permeten comparar mostres de mida diferent.
- ▶ Es poden llegir com a percentatges.
- ▶ Són la base de les probabilitats empíriques.

Exemple

$$f(\text{Chrome i Error}) = \frac{35}{1900} = 0.0184.$$

Aproximadament un 1.84% de totes les peticions són errors amb Chrome.

Freqüències condicionades

Quan volem comparar correctament, sovint hem de condicionar.

Condicionar per columnes

$$f(A_i | B_j) = \frac{n_{ij}}{n_{\cdot j}}$$

Distribució de A dins la subpoblació B_j .

Condicionar per files

$$f(B_j | A_i) = \frac{n_{ij}}{n_{i\cdot}}$$

Distribució de B dins la subpoblació A_i .

Missatge important


No és el mateix $f(A_i \cap B_j)$ que $f(B_j | A_i)$. Una pregunta sobre risc, error o rendiment acostuma a ser una pregunta condicionada.

Exemple: percentatge d'error per navegador

Navegador	Total	Errors	$f(\text{Error} \mid \text{Navegador})$
Chrome	880	35	3.98%
Firefox	470	22	4.68%
Safari	300	28	9.33%
Edge	250	25	10.00%

Lectura

La freqüència absoluta d'errors és més gran a Chrome, però el percentatge d'error és més alt a Safari i Edge.



Taules de contingència amb R

```
# dades: una fila per petició
logs <- read_csv("data/logs_web.csv")

# taula absoluta
tab <- table(logs$navegador, logs$estat)
addmargins(tab)

# taula relativa global
round(prop.table(tab), 3)

# percentatges per fila: estat condicionat al navegador
round(prop.table(tab, margin = 1), 3)

# percentatges per columna: navegador condicionat a l'estat
round(prop.table(tab, margin = 2), 3)
```


Objectiu pràctic

Que la mateixa taula es pugui regenerar quan arriben nous logs o quan canviem el període d'anàlisi.

Visualitzar una taula: del número al patró

```
library(ggplot2)

logs |>
  count(navegador, estat) |>
  group_by(navegador) |>
  mutate(prop = n / sum(n)) |>
  ggplot(aes(navegador, estat, fill = prop)) +
  geom_tile() +
  labs(fill = "Freq. cond.",
       x = "Navegador", y = "Estat") +
  theme_minimal()
```



Associació entre dues variables qualitatives

- ▶ Si la distribució de B és semblant per a tots els nivells de A , direm que no hi ha un patró clar d'associació.
- ▶ Si les freqüències condicionades canvien molt segons A , hi ha evidència descriptiva d'associació.
- ▶ La inferència estadística permetrà decidir si aquesta diferència pot ser compatible amb l'atzar.

Pregunta computacional

El tipus d'error depèn del navegador, del sistema operatiu o de la versió desplegada?

Prudència

Una taula de contingència pot mostrar associació, però no demostra causalitat.

Dues variables numèriques: preguntes bàsiques

En l'estudi descriptiu de dues variables numèriques volem respondre:

- ▶ Tenen aquestes variables alguna relació?
- ▶ La relació és positiva, negativa o nul·la?
- ▶ És aproximadament lineal o no lineal?
- ▶ Hi ha observacions anòmales?
- ▶ Podem predir una variable a partir de l'altra?

Exemples informàtics

- ▶ Mida de l'entrada i temps d'execució.
- ▶ Nombre d'usuaris concurrents i latència.
- ▶ Mida d'un fitxer i temps de compressió.
- ▶ Nombre de tests i temps de CI/CD.

La dada bivariant: parelles (x_i, y_i)


Per a cada observació i tenim dues mesures:

$$(x_i, y_i), \quad i = 1, \dots, n.$$

Execució	mida x	temps y	memòria
1	1000	12.4	45
2	2000	19.8	51
3	3000	29.1	59
4	4000	38.7	67
5	5000	51.0	77

Visualització natural


Cada parella (x_i, y_i) es representa com un punt en el pla.



Núvol de punts


El **núvol de punts** és la representació gràfica de totes les parelles (x_i, y_i) .

- ▶ Mostra tendències globals.
- ▶ Detecta relacions no lineals.
- ▶ Identifica valors atípics.
- ▶ Evita confiar només en una única mesura numèrica.




Patrons habituals en un núvol de punts


Relació positiva




Sense relació clara



Relació negativa



Relació no lineal



Les mitjanes de les dues variables són:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

La covariància mostral és:

$$S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Interpretació

- ▶ $S_{XY} > 0$: tendència conjunta positiva.
- ▶ $S_{XY} < 0$: tendència conjunta negativa.
- ▶ $S_{XY} \approx 0$: no hi ha tendència lineal clara.

Limitació

La covariància depèn de les unitats de mesura i és difícil de comparar entre problemes.

Correlació de Pearson

La correlació de Pearson normalitza la covariància:

$$r_{XY} = \frac{S_{XY}}{S_X S_Y}, \quad -1 \leq r_{XY} \leq 1.$$

Lectura del signe

- ▶ $r > 0$: relació lineal positiva.
- ▶ $r < 0$: relació lineal negativa.
- ▶ $r \approx 0$: no hi ha relació lineal clara.

Lectura de la magnitud

- ▶ $|r|$ proper a 1: relació lineal forta.
- ▶ $|r|$ proper a 0: relació lineal feble.
- ▶ r^2 : proporció descriptiva de variabilitat explicada per la recta.

```
bench <- read_csv("data/benchmark.csv")

# covariància i correlació
cov(bench$mida, bench$temps_ms)
cor(bench$mida, bench$temps_ms)

# gràfic bivariànt
ggplot(bench, aes(x = mida, y = temps_ms)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  theme_minimal()
```

Bones pràctiques

- ▶ Mirar sempre el gràfic abans d'interpretar r .
- ▶ Revisar valors atípics.
- ▶ No confondre correlació amb causalitat.
- ▶ Informar unitats i context.

Correlació: advertiments importants

1. Correlació no implica causalitat

Que dues variables es moguin juntes no vol dir que una causi l'altra.

2. Pearson mesura relació lineal

Una relació no lineal pot tenir $r \approx 0$.

3. Els outliers poden dominar

Un sol valor anòmal pot canviar molt la correlació.

4. Barrejar grups pot enganyar

La relació global pot ser diferent de la relació dins de cada grup.

Exemple informàtic

La relació entre mida d'entrada i temps pot dependre de l'algoritme, del maquinari i de la memòria cau.

Recta de regressió: primera idea

La recta de regressió resumeix una relació lineal entre dues variables:

$$\hat{y} = a + bx.$$

- ▶ x : variable explicativa o predictora.
- ▶ y : variable resposta.
- ▶ b : canvi mitjà en y per una unitat més de x .
- ▶ a : valor predit quan $x = 0$.

Criteri

Triem la recta que minimitza la suma de quadrats dels residus:

$$\sum_{i=1}^n [y_i - (a + bx_i)]^2.$$

Coeficients de la recta

La recta ajustada és:

$$\hat{y} = a + bx.$$

Els coeficients es calculen com:

$$b = \frac{S_{XY}}{S_X^2}, \quad a = \bar{y} - b\bar{x}.$$

Interpretació computacional


Si x és la mida de l'entrada i y és el temps d'execució, b estima l'increment mitjà de temps quan augmentem una unitat la mida d'entrada.

Atenció

La recta és un resum descriptiu. No garanteix que el fenomen sigui realment lineal ni que pugui extrapolar-se fora del rang observat.

Exemple: mida de l'entrada i temps d'execució

<i>mida</i>	<i>temps</i>	$\widehat{\text{temps}}$	residu
1000	12.4	11.7	0.7
2000	19.8	21.3	-1.5
3000	29.1	30.9	-1.8
4000	38.7	40.5	-1.8
5000	51.0	50.1	0.9
6000	61.8	59.7	2.1



Model descriptiu

$$\widehat{\text{temps}} = 2.1 + 0.0096 \cdot \text{mida}.$$

Regressió amb R

```
bench <- read_csv("data/benchmark.csv")

model <- lm(temps_ms ~ mida, data = bench)
summary(model)

# coeficients de la recta
coef(model)

# prediccions i residus
bench$predicció <- predict(model)
bench$residu <- residuals(model)

# grafic amb recta ajustada
ggplot(bench, aes(mida, temps_ms)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE) +
  theme_minimal()
```

Predicció i residus

Per a un valor x^* , la predicció és:

$$\hat{y}^* = a + bx^*.$$

El residu d'una observació és:

$$e_i = y_i - \hat{y}_i.$$


Quan confiar més en una predicció?

- ▶ x^* és dins el rang observat.
- ▶ El núvol de punts és aproximadament lineal.
- ▶ No hi ha outliers dominants.
- ▶ Els residus no mostren patrons evidents.

Quan desconfiar?

- ▶ Extrapolem fora del rang.
- ▶ La relació és clarament corba.
- ▶ Hi ha canvis de règim.
- ▶ Barrejar grups amaga diferències.


Mirar residus: detectar el que la recta no explica



Interpretació

- ▶ Residus al voltant de zero: ajust raonable.
- ▶ Patró corbat: la recta és massa simple.
- ▶ Residus molt grans: possibles outliers.
- ▶ Variabilitat creixent: la incertesa depèn de x .

De la descriptiva bivariant al modelatge



Qualitatives

Taules, percentatges condicionats i comparació de perfils.

Numèriques

Núvols de punts, correlació, regressió i residus.

Pont amb temes futurs

Inferència, contrastos d'hipòtesis, regressió, classificació i avaluació de models.