

Probabilitat I

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

La probabilitat com a llenguatge per raonar amb dades, algorismes i sistemes incerts

Per què probabilitat en Enginyeria Informàtica?

- ▶ Molts sistemes informàtics no són deterministes a escala observable.
- ▶ Treballem amb **errors, fallades, latències, mostres, classificadors, soroll i decisions sota incertesa**.
- ▶ La probabilitat permet modelitzar:
 - pèrdua de paquets en una xarxa,
 - falsos positius en un detector,
 - col·lisions en hashing,
 - experiments A/B,
 - filtres de correu brossa,
 - fiabilitat de sistemes distribuïts.

Idea clau

No n'hi ha prou amb dir “ha passat” o “no ha passat”. Volem quantificar **com de probable** és i com canvia aquesta probabilitat quan tenim nova informació.


Dades + model + simulació
→ decisió informada

Objectius del tema

Al final d'aquest tema hauríeu de poder:

1. Interpretar la probabilitat com a freqüència relativa a llarg termini i com a model.
2. Definir espai mostral, esdeveniments, complementaris, unions i interseccions.
3. Calcular probabilitats a partir de taules de freqüències.
4. Entendre i aplicar la probabilitat condicionada.
5. Identificar esdeveniments independents.
6. Aplicar la fórmula de probabilitat total i el teorema de Bayes.
7. Verificar resultats amb simulació en R.
8. Connectar aquests conceptes amb classificació, detecció d'errors i monitoratge de sistemes.

Mapa del tema



Pregunta transversal

Com actualitzem una probabilitat quan observem una nova evidència?

Un problema històric: de Méré i Fermat

Joc 1

Llancem un dau 4 vegades. Guanyem si surt almenys un 6.

$$\mathbb{P}(\text{guanyar}) = 1 - \left(\frac{5}{6}\right)^4 = 0.5177.$$

Joc 2

Llancem dos daus 24 vegades. Guanyem si surt almenys un doble 6.

$$\mathbb{P}(\text{guanyar}) = 1 - \left(\frac{35}{36}\right)^{24} = 0.4914.$$

Lliçó

Una intuïció aparentment raonable pot fallar. La probabilitat ens dona una manera formal de comprovar-la.

Càlcul exacte + simulació
⇒ comprensió del fenomen

El mateix problema amb R

```
# Probabilitats exactes
p_joc1 <- 1 - (5/6)^4
p_joc2 <- 1 - (35/36)^24

p_joc1
p_joc2

# Simulació del segon joc
set.seed(123)
B <- 100000
guanya <- replicate(B, {
  daus1 <- sample(1:6, size = 24, replace = TRUE)
  daus2 <- sample(1:6, size = 24, replace = TRUE)
  any(daus1 == 6 & daus2 == 6)
})
mean(guanya)
```

Missatge computacional

La simulació no substitueix la teoria, però ajuda a validar càlculs, detectar errors d'intuïció i entendre la variabilitat.


Freqüències relatives i probabilitats

Per esdeveniments aleatoris independents repetits moltes vegades:

$$\text{freqüència relativa} = \frac{\text{nombre d'èxits}}{\text{nombre de repeticions}}$$

$$\text{freqüència relativa} \approx \mathbb{P}(\text{èxit}).$$

- ▶ Amb poques repeticions pot variar força.
- ▶ Amb moltes repeticions tendeix a estabilitzar-se.
- ▶ Aquesta és la base de la simulació Monte Carlo.



Un patró de simulació reutilitzable

```
set.seed(2026)
B <- 5000

simula_joc <- function() {
  daus1 <- sample(1:6, 24, replace = TRUE)
  daus2 <- sample(1:6, 24, replace = TRUE)
  any(daus1 == 6 & daus2 == 6)
}

resultats <- replicate(B, simula_joc())
freq_acumulada <- cumsum(resultats) / seq_len(B)
```

Bones pràctiques

- ▶ Fixar una llavor amb `set.seed()`.
- ▶ Escriure funcions petites.
- ▶ Separar simulació, càlcul i visualització.
- ▶ Guardar el codi en un projecte de RStudio/Posit i GitHub.

Esdeveniments a partir d'una taula de dades

Suposem un registre de 120 peticions a un sistema web:

	Error	No error	Total
Mòbil	25	50	75
Escriptori	20	25	45
Total	45	75	120

- ▶ E : la petició acaba amb error.
- ▶ M : la petició ve de mòbil.
- ▶ D : la petició ve d'escriptori.

$$\mathbb{P}(E) = 45/120 = 0.375,$$

$$\mathbb{P}(M) = 75/120 = 0.625,$$

$$\mathbb{P}(D \cap E) = 20/120 = 0.1667.$$

Unions, interseccions i complementaris

Regla de la unió


$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

Complementari

$$\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A).$$

Exemple

$$\mathbb{P}(D \cup E) = 0.375 + 0.375 - 0.1667 = 0.5833.$$



La intersecció no s'ha de comptar dues vegades

Taules de probabilitats amb R

```
peticions <- tibble::tribble(  
  ~dispositiu, ~estat, ~n,  
  "mobil", "error", 25,  
  "mobil", "no_error", 50,  
  "escriptori", "error", 20,  
  "escriptori", "no_error", 25  
)  
  
# Taula de freqüències absolutes  
xt <- xtabs(n ~ dispositiu + estat, data = peticions)  
addmargins(xt)  
  
# Taula de probabilitats relatives  
round(prop.table(xt), 4)  
  
# Probabilitats condicionades per dispositiu  
round(prop.table(xt, margin = 1), 4)
```

Connexió amb descriptiva bivariant

Les taules de contingència també són una porta d'entrada natural a la probabilitat.

Definició formal de probabilitat

- **Espai mostral** Ω : conjunt de tots els resultats possibles.
- **Esdeveniments**: subconjunts de Ω .
- Una probabilitat és una funció

$$\mathbb{P} : \mathcal{E} \longrightarrow [0, 1]$$

que assigna un nombre a cada esdeveniment.

Axiomes bàsics


1. $0 \leq \mathbb{P}(A) \leq 1$.
2. $\mathbb{P}(\Omega) = 1$ i $\mathbb{P}(\emptyset) = 0$.
3. Si A i B són disjunts:

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B).$$

Interpretació computacional

Un esdeveniment pot ser: “temps de resposta > 1 segon”, “paquet perdut”, “classificador diu spam”, “test automàtic falla”.

Espai mostral en un sistema informàtic



Traducció estadística

Cada filtre sobre les dades defineix un esdeveniment. Les probabilitats poden estimar-se com a freqüències relatives o modelitzar-se teòricament.

Definició

La probabilitat que passi A sabent que ha passat B és:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0.$$

Exemple

Probabilitat que una petició tingui error sabent que ve d'escriptori:

$$\mathbb{P}(E \mid D) = \frac{\mathbb{P}(E \cap D)}{\mathbb{P}(D)} = \frac{20/120}{45/120} = 0.4444.$$

Interpretació

Condicionar vol dir canviar la població de referència. Ja no mirem totes les peticions, només les que compleixen D .

Definició

Dos esdeveniments A i B són independents si:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Equivalentment, si $\mathbb{P}(B) > 0$:

$$\mathbb{P}(A \mid B) = \mathbb{P}(A).$$

- ▶ Si saber B no canvia la probabilitat de A , no hi ha informació addicional.
- ▶ En dades reals, la independència exacta és rara.

En informàtica

No assumiu independència sense pensar-hi: errors de xarxa, caigudes de serveis i temps de resposta poden estar correlacionats.

Comprovar independència amb dades

```
# Probabilitat d'error global
p_error <- sum(xt[, "error"]) / sum(xt)

# Probabilitat d'error condicionada pel dispositiu
p_error_cond <- prop.table(xt, margin = 1)[, "error"]

p_error
p_error_cond

# Si són molt diferents, el dispositiu aporta informació
p_error_cond - p_error
```

Important

Amb una mostra petita, diferències petites poden ser només soroll. La inferència estadística ajudarà a decidir si la diferència és compatible amb l'atzar.

El problema dels aniversaris

Volem calcular la probabilitat que, entre k persones, almenys dues comparteixin aniversari.

- És més fàcil calcular el complementari: cap aniversari repetit.

$$\mathbb{P}(\text{cap repetit}) = \frac{365 \cdot 364 \cdot \dots \cdot (365 - k + 1)}{365^k}.$$

$$\mathbb{P}(\text{almenys un repetit}) = 1 - \mathbb{P}(\text{cap repetit}).$$

k	$\mathbb{P}(\text{repetit})$
10	0.1169
20	0.4114
23	0.5073
30	0.7063

Sorprenent?

Amb 23 persones ja superem el 50%.

Simular el problema dels aniversaris

```
simula_aniversaris <- function(k) {  
  dies <- sample(1:365, size = k, replace = TRUE)  
  any(duplicated(dies))  
}  
  
set.seed(123)  
B <- 10000  
ks <- c(10, 20, 23, 30)  
  
prob_sim <- sapply(ks, function(k) {  
  mean(replicate(B, simula_aniversaris(k)))  
})  
  
tibble::tibble(k = ks, prob_simulada = prob_sim)
```

Lectura computacional

Aquest exemple mostra com una probabilitat aparentment complicada es pot entendre amb una combinació de complementaris i simulació.


Particions de l'espai mostral

Una partició divideix Ω en esdeveniments disjunts:

$$\Omega = H_1 \cup H_2 \cup \dots \cup H_n, \quad H_i \cap H_j = \emptyset.$$

Qualsevol esdeveniment A es pot descompondre com:

$$A = (A \cap H_1) \cup \dots \cup (A \cap H_n).$$



Fórmula de probabilitat total

Si $H_1, \dots, H_n$ formen una partició:

$$\mathbb{P}(A) = \mathbb{P}(A \cap H_1) + \dots + \mathbb{P}(A \cap H_n).$$

Com que

$$\mathbb{P}(A \cap H_i) = \mathbb{P}(A \mid H_i)\mathbb{P}(H_i),$$

tenim:

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \mid H_i)\mathbb{P}(H_i)$$

Interpretació

La probabilitat global de A és una mitjana ponderada de les probabilitats condicionades de A dins de cada grup.

Teorema de Bayes

Fórmula

Si $H_1, \dots, H_n$ formen una partició i observem A :

$$\mathbb{P}(H_j | A) = \frac{\mathbb{P}(A | H_j)\mathbb{P}(H_j)}{\sum_{i=1}^n \mathbb{P}(A | H_i)\mathbb{P}(H_i)}$$

- ▶ $\mathbb{P}(H_j)$: probabilitat abans d'observar A .
- ▶ $\mathbb{P}(A | H_j)$: versemblança de l'evidència.
- ▶ $\mathbb{P}(H_j | A)$: probabilitat després d'observar A .

Lectura informàtica

Bayes és el nucli de molts raonaments de diagnòstic: spam, alertes, tests automàtics, detecció d'intrusions i classificadors probabilístics.

Exemple: filtre de correu brossa

Un compte de correu rep missatges:

- ▶ 30% són spam: $\mathbb{P}(S) = 0.3$.
- ▶ Si és spam, el 30% conté una paraula sospitosa V : $\mathbb{P}(V | S) = 0.3$.
- ▶ Si no és spam, l'1% conté V : $\mathbb{P}(V | \bar{S}) = 0.01$.

Si un missatge conté V , quina és la probabilitat que sigui spam?

$$\begin{aligned}\mathbb{P}(V) &= 0.3 \cdot 0.3 + 0.01 \cdot 0.7 \\ &= 0.097,\end{aligned}$$

$$\begin{aligned}\mathbb{P}(S | V) &= \frac{\mathbb{P}(V | S)\mathbb{P}(S)}{\mathbb{P}(V)} \\ &= \frac{0.3 \cdot 0.3}{0.097} = 0.9278.\end{aligned}$$

Conclusió

La paraula V és molt informativa, però no perfecta.

Bayes amb una taula en R

```
prior_spam <- 0.30
p_v_spam <- 0.30
p_v_no_spam <- 0.01

p_v <- p_v_spam * prior_spam +
      p_v_no_spam * (1 - prior_spam)

posterior_spam <- p_v_spam * prior_spam / p_v
posterior_spam
```

Extensió natural

En lloc d'una sola paraula, podem tenir moltes característiques: paraules, domini, adjunts, hora d'enviament, historial del remitent... Aquesta és la porta d'entrada als classificadors probabilístics.

Exemple: alarma d'un sistema

Un sistema de monitoratge dispara una alarma si detecta una incidència.

- Probabilitat real d'incidència: $\mathbb{P}(I) = 0.01$.
- Si hi ha incidència, l'alarma es dispara amb probabilitat 0.97.
- Si no hi ha incidència, hi ha falsa alarma amb probabilitat 0.02.

Si sona l'alarma, quina és la probabilitat que hi hagi incidència?

$$\begin{aligned}\mathbb{P}(I | A) &= \frac{\mathbb{P}(A | I)\mathbb{P}(I)}{\mathbb{P}(A | I)\mathbb{P}(I) + \mathbb{P}(A | \bar{I})\mathbb{P}(\bar{I})} \\ &= \frac{0.97 \cdot 0.01}{0.97 \cdot 0.01 + 0.02 \cdot 0.99} \\ &= 0.3288.\end{aligned}$$

Lliçó

Una alarma molt bona pot tenir una probabilitat posterior moderada si l'esdeveniment real és molt rar.

Base rate fallacy: el risc d'oblidar la prevalença

- ▶ L'alarma té sensibilitat alta: $\mathbb{P}(A | I) = 0.97$.
- ▶ Però la incidència és molt rara: $\mathbb{P}(I) = 0.01$.
- ▶ Moltes alarmes provenen de casos sense incidència, perquè són molt més nombrosos.

	Alarma	No alarma
Incidència	0.0097	0.0003
No incidència	0.0198	0.9702
Total	0.0295	0.9705

Traducció informàtica

En detecció d'intrusions, frau o anomalies, no podem mirar només la taxa d'encert. Cal tenir en compte la freqüència real de l'esdeveniment.

$$\frac{0.0097}{0.0295} = 0.3288$$

Exemple: qualitat de software o hardware

Tres proveïdors fabriquen components. Les quotes i percentatges defectuosos són:

Proveïdor	Quota	Defectuosos
A	70%	4%
B	24%	3%
C	6%	1%

- Probabilitat que un component sigui defectuós?
- Si és defectuós, probabilitat que sigui de C?
- Si funciona, probabilitat que sigui de B?

$$\begin{aligned}\mathbb{P}(D) &= 0.04 \cdot 0.70 + 0.03 \cdot 0.24 + 0.01 \cdot 0.06 \\ &= 0.0358,\end{aligned}$$

$$\mathbb{P}(C \mid D) = \frac{0.01 \cdot 0.06}{0.0358} = 0.0168,$$

$$\mathbb{P}(B \mid \overline{D}) = \frac{0.97 \cdot 0.24}{1 - 0.0358} = 0.2414.$$

Codi genèric per a probabilitat total i Bayes

```
proveidors <- tibble::tribble(  
  ~proveidor, ~quota, ~prob_defecte_cond,  
  "A",        0.70,    0.04,  
  "B",        0.24,    0.03,  
  "C",        0.06,    0.01  
)  
  
prob_defecte_total <- sum(  
  proveidors$quota * proveidors$prob_defecte_cond  
)  
  
proveidors <- proveidors |>  
  dplyr::mutate(  
    prob_proveidor_si_defecte =  
      quota * prob_defecte_cond / prob_defecte_total  
  )  
  
proveidors
```

Programar estadística també és programar bé

Noms clars, funcions petites i informes reproduïbles redueixen errors matemàtics i errors de codi.


Quan la probabilitat exacta és difícil

En problemes reals, el càlcul exacte pot ser difícil:

- ▶ molts components,
- ▶ dependències entre fallades,
- ▶ regles complexes,
- ▶ grans volums de dades,
- ▶ probabilitats rares.

Estratègia

Simular moltes vegades el sistema i estimar la probabilitat com a freqüència relativa.



Exemple: fiabilitat d'un sistema amb rèpliques

Un servei funciona si almenys 2 de 3 servidors estan actius. Cada servidor falla amb probabilitat 0.05.

```
set.seed(123)
B <- 100000

simula_sistema <- function() {
  actiu <- rbinom(n = 3, size = 1, prob = 0.95)
  sum(actiu) >= 2
}

funciona <- replicate(B, simula_sistema())
mean(funciona)
```

Lectura

Aquest tipus de simulació connecta probabilitat, arquitectura de sistemes i presa de decisions sobre redundància.

Accelerar simulacions amb paral·lelització

```
library(future)
library(furrr)

plan(multisession, workers = 4)

B <- 10000
resultats <- future_map_dbl(1:B, function(i) {
  actiu <- rbinom(n = 3, size = 1, prob = 0.95)
  as.numeric(sum(actiu) >= 2)
})

mean(resultats)
```

Missatge

La probabilitat proporciona el model; la computació permet repetir-lo moltes vegades.

Important

La paral·lelització és útil quan cada simulació és prou costosa. Per problemes petits, el cost de coordinar processos pot no compensar.