

Probabilitat II

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

De comptar esdeveniments a simular sistemes: errors, intents, connexions i càrrega

Per què variables aleatòries discretes en informàtica?

- ▶ Molts fenòmens informàtics són **comptatges**:
 - nombre de paquets perduts,
 - nombre d'errors en una bateria de tests,
 - nombre d'intents fins al primer èxit,
 - nombre de connexions per segon,
 - nombre de bugs detectats en una versió,
 - nombre de col·lisions en una taula hash.
- ▶ Les distribucions discretes donen models simples per simular i raonar sobre aquests comptatges.

Idea clau

Una variable aleatòria transforma un fenomen incert en un nombre que podem **calcular, simular i visualitzar**.


Sistema incert $\rightarrow$ variable aleatòria $X \rightarrow$ distribució $\rightarrow$ decisió

Objectius del tema

Al final d'aquest tema hauríeu de poder:

1. Definir una variable aleatòria discreta i la seva distribució.
2. Calcular i interpretar esperança i variància.
3. Reconèixer models de Bernoulli, binomial, geomètric i Poisson.
4. Traduir problemes d'informàtica a variables aleatòries.
5. Calcular probabilitats exactes amb fórmules i amb R.
6. Verificar resultats amb simulació Monte Carlo.
7. Interpretar el paper de la variabilitat en sistemes computacionals.

Mapa del tema



Pregunta transversal

Quina distribució descriu millor el comptatge que observem?

Variable aleatòria: de l'espai mostral al nombre

Definició

Una **variable aleatòria** és una funció

$$X : \Omega \longrightarrow \mathbb{R}$$

que assigna un valor numèric a cada resultat possible d'un experiment aleatori.

- ▶ Els esdeveniments es poden escriure com $\{X = a\}$, $\{X \leq a\}$, etc.
- ▶ La distribució ens diu amb quina probabilitat pren cada valor.

Exemple clàssic

Llancem dos daus i definim

$$X = \text{suma dels resultats.}$$

Aleshores X pot valer $2, 3, \dots, 12$.

Exemple informàtic

Enviem 100 paquets i definim

$$X = \text{nombre de paquets perduts.}$$

Distribució d'una variable discreta


Distribució

Per a una variable discreta X :

$$0 \leq \mathbb{P}(X = a) \leq 1, \quad \sum_a \mathbb{P}(X = a) = 1.$$

- ▶ La distribució és una taula de valors i probabilitats.
- ▶ També es pot representar amb un gràfic de barres.

x	2	3	4	...	11
$\mathbb{P}(X = x)$	1/36	2/36	3/36	...	2/36



Distribucions discretes amb R

```
# Distribució exacta de la suma de dos daus
resultats <- expand.grid(dau1 = 1:6, dau2 = 1:6)
resultats$suma <- resultats$dau1 + resultats$dau2

table(resultats$suma)
prop.table(table(resultats$suma))
```

Lectura computacional

- ▶ Generem tot l'espai mostral amb `expand.grid()`.
- ▶ Convertim resultats en valors de X .
- ▶ Comptem freqüències i les transformem en probabilitats.

Esperança: valor mitjà esperat

Definició

L'esperança d'una variable aleatòria discreta és

$$\mathbb{E}(X) = \mu_X = \sum_a a \mathbb{P}(X = a).$$

- ▶ És el valor mitjà que esperaríem si repetíssim l'experiment moltes vegades.
- ▶ No ha de coincidir necessàriament amb un valor possible de X .

Interpretació informàtica

Si X és el nombre de tests que fallen en cada execució automàtica, $\mathbb{E}(X)$ és el nombre mitjà de fallades esperades per execució.

No és una predicció exacta

És un resum del comportament mitjà a llarg termini.

Variància: quant fluctua el resultat?

Definició

La variància és

$$\text{Var}(X) = \sigma_X^2 = \sum_a (a - \mu_X)^2 \mathbb{P}(X = a).$$

- ▶ Mesura la dispersió respecte l'esperança.
- ▶ Una variància alta indica resultats més inestables.

Exemple computacional

Dos algoritmes poden tenir el mateix temps mitjà però variàncies diferents:

- ▶ un és estable,
- ▶ l'altre és ràpid sovint però molt lent en alguns casos.

Missatge

La mitjana sola pot ser insuficient per a decidir.

Mateixa esperança, risc diferent

Aposta A

Guanyem +1 amb probabilitat 18/37 i perdem -1 amb probabilitat 19/37.

$$\mathbb{E}(X) = \frac{18}{37} - \frac{19}{37} = -\frac{1}{37}.$$

Aposta B

Guanyem +35 amb probabilitat 1/37 i perdem -1 amb probabilitat 36/37.

$$\mathbb{E}(Y) = 35\frac{1}{37} - \frac{36}{37} = -\frac{1}{37}.$$

Conclusió

Tenen la mateixa esperança, però no el mateix risc: $\text{Var}(X) \approx 1.002$ i $\text{Var}(Y) \approx 36.001$.

Esperança i variància amb R

```
# Aposta A
x <- c(1, -1)
px <- c(18/37, 19/37)
EX <- sum(x * px)
VX <- sum((x - EX)^2 * px)

# Aposta B
y <- c(35, -1)
py <- c(1/37, 36/37)
EY <- sum(y * py)
VY <- sum((y - EY)^2 * py)

c(EX = EX, VarX = VX, EY = EY, VarY = VY)
```

Missatge computacional

Les fórmules són importants, però també ho és saber transformar-les en codi verificable.

Model

Una variable Bernoulli només pot prendre dos valors:

$$X = 1 \quad \text{èxit}, \quad X = 0 \quad \text{fracàs.}$$

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p = q.$$

$$\mathbb{E}(X) = p, \quad \text{Var}(X) = pq.$$

Exemples informàtics

- ▶ Un test passa o falla.
- ▶ Un paquet arriba o es perd.
- ▶ Un usuari clica o no clica.
- ▶ Una petició HTTP retorna error o no.

Model

Fem n experiments Bernoulli independents, tots amb probabilitat d'èxit p . Si X és el nombre d'èxits, escrivim

$$X \sim B(n, p).$$

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n.$$

$$\mathbb{E}(X) = np, \quad \text{Var}(X) = np(1 - p).$$

Quan l'usem?

Quan comptem quants èxits hi ha en un nombre fix d'intents independents.

Binomial en informàtica: paquets perduts

Plantejament

Enviem $n = 100$ paquets. Cada paquet es perd amb probabilitat $p = 0.02$, independentment dels altres.

$X = \text{nombre de paquets perduts} \sim B(100, 0.02)$.

- Nombre esperat de paquets perduts:
 $\mathbb{E}(X) = 100 \cdot 0.02 = 2$.
- Variància: $\text{Var}(X) = 100 \cdot 0.02 \cdot 0.98 = 1.96$.

Pregunta

Quina és la probabilitat de perdre més de 5 paquets?

$$\mathbb{P}(X > 5) = 1 - \mathbb{P}(X \leq 5).$$

Interpretació

Això pot ajudar a fixar llindars d'alerta en una xarxa.

Binomial amb R: càlcul exacte i simulació

```
n <- 100
p <- 0.02


# Càlcul exacte
1 - pbinom(5, size = n, prob = p)

# Simulació Monte Carlo
set.seed(123)
B <- 100000
x <- rbinom(B, size = n, prob = p)
mean(x > 5)
mean(x)
var(x)
```

Dues maneres complementàries

- ▶ `pbinom()` dona el càlcul exacte del model.
- ▶ `rbinom()` simula molts sistemes possibles.

Distribució binomial: forma de la distribució



Lectura

Encara que la mitjana sigui 2, poden aparèixer valors més grans. La distribució quantifica com de sorprenents són.

Model

Fem experiments Bernoulli independents fins obtenir el primer èxit. Si X és el nombre de fracassos abans del primer èxit:

$$\mathbb{P}(X = k) = q^k p, \quad k = 0, 1, 2, \dots$$

$$\mathbb{E}(X) = \frac{q}{p}, \quad \text{Var}(X) = \frac{q}{p^2}.$$

Exemples informàtics

- Nombre de reintents abans que una connexió funcioni.
- Nombre de commits abans de detectar el primer test fallit.
- Nombre de peticions fins que apareix el primer error 500.

Plantejament

Una petició a un servei té probabilitat d'èxit $p = 0.8$. Definim

X = nombre de fracassos abans del primer èxit.

Aleshores

$$X \sim \text{Geom}(p = 0.8), \quad \mathbb{E}(X) = \frac{0.2}{0.8} = 0.25.$$

- ▶ $\mathbb{P}(X = 0) = 0.8$: funciona a la primera.
- ▶ $\mathbb{P}(X = 1) = 0.2 \cdot 0.8 = 0.16$.
- ▶ $\mathbb{P}(X \geq 3) = 0.2^3 = 0.008$.

Ús pràctic

Serveix per raonar sobre polítiques de reintent, timeouts i degradació del servei.

```
p <- 0.8

# P(X = k), on X = fracassos abans del primer èxit
dgeom(0:5, prob = p)

# P(X >= 3)
1 - pgeom(2, prob = p)

# Simulació
set.seed(123)
x <- rgeom(100000, prob = p)
mean(x)
var(x)
```

Detall important

En R, `rgeom()` segueix aquesta convenció: compta el nombre de fracassos abans del primer èxit.

Model

La distribució de Poisson modelitza el nombre d'esdeveniments en un interval de temps o espai:

$$X \sim \text{Pois}(\lambda).$$

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

$$\mathbb{E}(X) = \lambda, \quad \text{Var}(X) = \lambda.$$

Exemples informàtics

- ▶ Connexions per segon a un servidor.
- ▶ Errors per minut en un log.
- ▶ Incidències obertes per dia.
- ▶ Missatges que arriben a una cua.

Plantejament

Un servidor rep de mitjana 2.5 connexions per segon.

X = nombre de connexions en un segon $\sim \text{Pois}(2.5)$.

$$\mathbb{P}(X = 0) = e^{-2.5} \approx 0.082$$

$$\mathbb{P}(X = 1) = 2.5e^{-2.5} \approx 0.205$$

$$\mathbb{P}(X = 2) = \frac{2.5^2 e^{-2.5}}{2!} \approx 0.257$$

Pregunta operativa

Quina és la probabilitat de rebre 3 o més connexions en un segon?

$$\mathbb{P}(X \geq 3) = 1 - \mathbb{P}(X \leq 2).$$

Poisson amb R

```
lambda <- 2.5

# Probabilitats puntuals
pois_vals <- dpois(0:8, lambda = lambda)
round(pois_vals, 3)


# Probabilitat de 3 o més connexions
1 - ppois(2, lambda = lambda)

# Si l'interval és de 2 segons, lambda es multiplica per 2
1 - dpois(0, lambda = 2 * lambda)
```

Escalat temporal

Si el ritme mitjà és λ per segon, en t segons el paràmetre és $t\lambda$.

Distribució de Poisson: forma



Lectura

La massa es concentra al voltant de $\lambda = 2.5$, però hi ha probabilitat no nul·la de pics de càrrega.

Poisson i monitoratge: un llindar d'alerta

Context

Suposem que en condicions normals hi ha $\lambda = 2.5$ errors per minut. Volem activar una alerta si observem un nombre molt alt d'errors.

- ▶ Si el llindar és $X \geq 8$, calculem $\mathbb{P}(X \geq 8)$ sota el funcionament normal.
- ▶ Si aquesta probabilitat és petita, observar 8 o més errors pot indicar una anomalia.

Idea estadística

Un llindar d'alerta és una decisió basada en una probabilitat de cua.

Amb R

$$\mathbb{P}(X \geq 8) = 1 - \mathbb{P}(X \leq 7).$$

```
1 - ppois(7, 2.5)
```

Simulació Monte Carlo: quan el càlcul exacte no és còmode

```
set.seed(123)
B <- 100000

# Simulem 100000 segons d'activitat d'un servidor
connexions <- rpois(B, lambda = 2.5)

# Estimem probabilitats a partir de freqüències relatives
mean(connexions >= 3)
mean(connexions >= 8)

# Resums descriptius
mean(connexions)
var(connexions)
table(connexions)
```

Connexió amb el tema anterior

Les freqüències relatives de la simulació s'aproximen a les probabilitats del model.

Paral·lelització bàsica de simulacions amb R

```
library(future)
library(furrr)

plan(multisession, workers = 4)

simula_prob_cua <- function(i) {
  x <- rpois(100000, lambda = 2.5)
  mean(x >= 8)
}

set.seed(123)
resultats <- future_map_dbl(1:100, simula_prob_cua)

mean(resultats)
sd(resultats)
```

Per què és útil?

Quan repetim moltes simulacions, bootstrap o experiments de rendiment, la computació paral·lela redueix el temps d'espera.

Quina distribució triem?

Distribució	Pregunta típica	Exemple informàtic
Bernoulli	Èxit o fracàs?	Un test passa o falla
Binomial	Quants èxits en n intents?	Paquets perduts en 100 enviaments
Geomètrica	Quants fracassos abans del primer èxit?	Reintents abans d'una connexió exitosa
Poisson	Quants esdeveniments en un interval?	Connexions per segon, errors per minut

Estratègia

Primer identifiquem què estem comptant; després escollim el model.