

Probabilitat IV

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

Estadística computacional amb R, simulació i exemples d'enginyeria informàtica

Per què el TCL és central en estadística computacional?

- ▶ La mitjana de moltes contribucions independents tendeix a comportar-se com una normal.
- ▶ Això explica per què la normal apareix en errors de mesura, benchmarks repetits i estimadors.
- ▶ Permet quantificar incertesa sense conèixer exactament la distribució original.

Idea clau

Encara que les dades originals no siguin normals, la mitjana mostral pot ser aproximadament normal quan n és prou gran.

Objectius del tema

1. Recordar independència, suma d'esperances i suma de variàncies.
2. Formular el Teorema Central del Límit.
3. Aplicar el TCL a sumes i mitjanes.
4. Verificar-lo amb simulació Monte Carlo en R.
5. Connectar-lo amb estimació, intervals de confiança i benchmarking.

Variables independents i agregació

Si X i Y són independents:

$$\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y),$$

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

Per constants λ :

$$\mathbb{E}(\lambda X) = \lambda \mathbb{E}(X), \quad \text{Var}(\lambda X) = \lambda^2 \text{Var}(X).$$

Exemple

La durada total de 45 components independents és la suma de 45 durades individuals.

Atenció

La independència no és només una qüestió tècnica: si hi ha dependència, la variància agregada pot canviar molt.

Teorema Central del Límit

TCL clàssic

Si $X_1, \dots, X_n$ són independents i idènticament distribuïdes amb

$$\mathbb{E}(X_i) = \mu, \quad \text{Var}(X_i) = \sigma^2,$$

aleshores, per n prou gran,

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} \approx N\left(\mu, \frac{\sigma}{\sqrt{n}}\right).$$

- ▶ La desviació típica de $\bar{X}$ és $\sigma/\sqrt{n}$.
- ▶ Augmentar n redueix la incertesa de la mitjana.

Quan mesurem moltes vegades el temps d'execució d'un algoritme:

- ▶ cada execució té soroll: càrrega del sistema, memòria cau, processos concurrents;
- ▶ la mitjana de moltes execucions és més estable;
- ▶ el TCL justifica aproximar la distribució de la mitjana amb una normal.

Regla pràctica

No comparem algoritmes amb una sola execució. Repetim, resumim i quantifiquem incertesa.

Exemple: vida total de components

- ▶ 45 components funcionen un darrere l'altre.
- ▶ Cada component té vida mitjana 50 h i desviació típica 4 h.
- ▶ La durada total és $X = X_1 + \dots + X_{45}$.

$$\mathbb{E}(X) = 45 \cdot 50 = 2250, \quad \text{sd}(X) = \sqrt{45 \cdot 4^2} \approx 26.8.$$

Pel TCL:

$$X \approx N(2250, 26.8).$$

```
mu <- 45 * 50
sigma <- sqrt(45 * 4^2)
1 - pnorm(2300, mean = mu, sd = sigma)
```

Simulació del TCL amb dades no normals

```
library(tidyverse)
set.seed(123)
B <- 10000
n <- 40
mitjanes <- replicate(B, mean(rexp(n, rate = 1)))

tibble(mitjanes) |>
  ggplot(aes(mitjanes)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40) +
  geom_density(linewidth = 1) +
  theme_minimal()
```

Observació

Tot i que l'exponencial és asimètrica, les mitjanes simulades són molt més semblants a una normal.

Com canvia la distribució de la mitjana?

- ▶ Amb n petit, la mitjana conserva part de la forma original.
- ▶ Amb n gran, la forma s'aproxima a la normal.
- ▶ La variabilitat baixa com $1/\sqrt{n}$.

```
sim_mitjana <- function(n, B = 5000) {  
  replicate(B, mean(rexp(n, rate = 1)))  
}  
  
sd(sim_mitjana(5))  
sd(sim_mitjana(50))
```

Aproximació normal de proporcions

Connexió amb la binomial

Si $X \sim B(n, p)$, aleshores $\hat{p} = X/n$ és la mitjana de n Bernoulli. Pel TCL:

$$\hat{p} \approx N \left(p, \sqrt{\frac{p(1-p)}{n}} \right).$$

- ▶ Exemple: taxa d'errors en 10.000 peticions.
- ▶ Base dels intervals de confiança i tests per proporcions.

Paral·lelitzar simulacions Monte Carlo

```
library(furrr)
plan(multisession, workers = 4)

simula <- function(n) mean(rexp(n, rate = 1))
mitjanes <- future_map_dbl(1:10000, ~ simula(100))

mean(mitjanes)
sd(mitjanes)
```

Per què té sentit paral·lelitzar?

Cada repetició Monte Carlo és independent: és un cas natural de càlcul paral·lel.