

Inferència VI

Estadística – Grau en Enginyeria Informàtica

Curs 2026–27

Estadística computacional amb R, simulació i exemples d'enginyeria informàtica

Per què tests no paramètrics?

- ▶ Fins ara hem contrastat paràmetres: mitjanes, proporcions i variàncies.
- ▶ Ara contrastem estructures: independència o ajust a una distribució.
- ▶ Són especialment útils amb variables categòriques i taules de contingència.

Exemples informàtics

Sistema operatiu i tipus d'error; navegador i conversió; distribució esperada de codis d'estat HTTP.

Objectius

1. Formular tests χ^2 d'independència i d'ajustament.
2. Calcular valors observats i esperats.
3. Interpretar residus i contribucions.
4. Fer els tests amb `chisq.test()` en R.
5. Relacionar resultats amb decisions sobre producte o sistema.

Dos tipus de tests χ^2

Independència

H_0 : dues variables són independents.

Exemple: tipus de dispositiu i error.

Ajustament

H_0 : les dades segueixen una distribució donada.

Exemple: freqüències de codis HTTP segons proporcions esperades.

En ambdós casos, l'estadístic és gran quan observat i esperat difereixen molt.

Test d'independència

Taula de contingència

Per cada cel·la (i, j) tenim observat o_{ij} i esperat

$$e_{ij} = \frac{(\text{total fila } i)(\text{total columna } j)}{n}.$$

$$E = \sum_{i,j} \frac{(o_{ij} - e_{ij})^2}{e_{ij}} \sim \chi^2_{(f-1)(c-1)}.$$

Condicció pràctica

Els esperats haurien de ser prou grans, habitualment $e_{ij} \geq 5$.

Exemple: dispositiu i error

	Error	Sense error
Mòbil	48	952
Escriptori	22	978

```
taula <- matrix(c(48, 952, 22, 978),  
               nrow = 2, byrow = TRUE)  
rownames(taula) <- c("mòbil", "desktop")  
colnames(taula) <- c("error", "ok")  
chisq.test(taula, correct = FALSE)
```

H_0 : dispositiu i error són independents.

Mirar més enllà del p-valor

```
res <- chisq.test(taula, correct = FALSE)
res$expected      # valors esperats
res$residuals     # residus de Pearson
res$stdres        # residus estandarditzats
```

- ▶ Les cel·les amb residus grans expliquen la dependència.
- ▶ Això ajuda a traduir el test en accions concretes.

Interpretació

No només interessa si hi ha relació, sinó on apareix la diferència.

Test d'ajustament

Una sola variable categòrica

Tenim freqüències observades o_i i probabilitats esperades p_i .

$$e_i = np_i, \quad E = \sum_i \frac{(o_i - e_i)^2}{e_i}.$$

H_0 : les dades segueixen les probabilitats p_i .

```
observat <- c(200, 720, 80)
esperat_p <- c(.2, .75, .05)
chisq.test(observat, p = esperat_p)
```

Exemple: codis HTTP

En condicions normals esperem:

- ▶ 2xx: 92%,
- ▶ 3xx: 5%,
- ▶ 4xx: 2%,
- ▶ 5xx: 1%.

Avui observem 10.000 respostes: 9000, 520, 260, 220.

```
obs <- c(9000, 520, 260, 220)
p0 <- c(.92, .05, .02, .01)
chisq.test(obs, p = p0)
```

Pregunta

El patró d'avui és compatible amb el funcionament normal?

Visualització de contribucions

```
res <- chisq.test(obs, p = p0)
contrib <- (obs - res$expected)^2 / res$expected

tibble(codi = c("2xx", "3xx", "4xx", "5xx"), contrib) |>
  ggplot(aes(codi, contrib)) +
  geom_col() +
  theme_minimal()
```

Idea

Les contribucions indiquen quines categories expliquen el rebuig de H_0 .

- ▶ Requereix freqüències esperades prou grans.
- ▶ No mesura causalitat.
- ▶ Amb mostres molt grans, diferències petites poden ser significatives.
- ▶ Cal complementar amb mida de l'efecte i interpretació de domini.

Opcional

Per taules 2×2 , es pot mirar també odds ratio o diferència de proporcions.